湖北工业大学毕业设计（论文）资料袋

湖北工業大學

毕 业 设 计（论 文）

题 目　基于改进 YOLOv11 的二手手机外观瑕疵检测与智能定级系统设计

姓　　名	侯天博
学　　号	2211631213
所在学院	底特律绿色工业学院
专业班级	22 底_软件 2
指导教师	熊才权
日　　期	2026 年 5 月 29 日

原创性声明

本人郑重声明：所呈交的学位论文是本人在导师的指导下独立进行研究所取得的研究成果。除了文中特别加以标注引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写的成果作品。本人完全意识到本声明的法律后果由本人承担。

作者签名：侯天博　　日期：2026年5月29日

学位论文版权使用授权书

本学位论文作者完全了解学院有关保管、使用学位论文的规定，同意学院保留并向有关学位论文管理部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权省级优秀学士学位论文评选机构将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

本学位论文属于

1、保密　□，在　　年解密后适用本授权书。

2、不保密 ☑

（请在以上相应方框内打“√”）

作者签名：侯天博　　日期：2026年5月29日

导师签名：[illegible]　　日期：2026年5月29日

摘　要

随着二手智能手机交易量不断增加，传统的人工目测的方式进行外观成色判断存在主观性强、工作效率低、缺少统一评判标准等问题，严重影响二手手机市场的发展。为解决这些问题，在此基础上，基于 YOLOv11 目标检测算法提出一种面向中小商户的二手手机外观缺陷自动识别及等级划分的方法。

本文的主要研究工作与成果如下：

第一，在特定多材质混合场景下的工业数据集不足的情况下，本文自制一个包含 2707 张高质量实拍图像的手机表面缺陷专用数据集。利用严格的标注标准及轻度物理增强方法避免了之前基于 AI 辅助标注造成的大量虚假正例带来的影响，使得对于小目标检测有了较好的数据支持。

第二，进行 10 组消融实验进一步研究特定算法模块对于手机强反光、目标极端长宽比等情况下的表现。结果表明，在对比盲目使用 CBAM 注意力模块以及 Inner-IoU 损失所造成的负面影响后，根据实际情况而设定的空间翻转（flipud=0.5）及动态背景均衡（mosaic=0.4）的数据增强方法更具有实用性。这种方法无需增加额外参数量的情况下，使基础模型的 mAP@0.5 达到 96.5%，同时提高召回率至 92.16%。

最后，实现从视觉检测直至商业评价的整体流程。提出一种“对角两拍法”的多角度拍摄方式以及利用对数平滑的一种非线性加权扣分的数学模型，将视觉缺陷转化为商业成色等级（S/A/B/C/D）。在工程技术上使用 ONNX 推理框架、FastAPI 异步后端和微信小程序前端进行开发，在保证单次推理耗时小于 150 毫秒的同时做到全流程耗时不超过 1.5 秒。

本研究不但证明了物理先验对于小目标缺陷检测优化的有效性，而且给二手手机市场成色标准化评定提供了一种低成本、低门槛的实用工程技术解决方案。

关键词：YOLOv11；缺陷检测；消融实验；智能定级；数据增强

Abstract

Since the second-hand mobile phone market is still growing, the conventional manual visual assessment to determine the condition is revealing some critical pain points, including high level of subjectivity, inefficiency, and absence of uniform quantitative criteria that strongly hinder the standardization of the industry. To solve these problems, the current study offers to design and implement an intelligent appearance defect detection and quantification system of a second-hand mobile phone based on the YOLOv11 algorithm of object detection, but with a smaller scope of use (small and mid-size retailers).

The main contributions and results of this study are as follows:

Then, to address the absence of industrial data on particular multi-material mix conditions, a special smartphone surface defect dataset consisting of 2,707 high-purity real-shot shots was built anew. With stringent manual annotation guidelines and gentle physical augmentation methods, the initial AI-assisted annotation noise of high-noise false-positive interference was efficiently tackled and a solid data basis of small object perception was established.

Secondly, the mechanisms of failures of particular algorithm elements in conditions with high reflections and extreme aspect ratios were also thoroughly explored using 10 sets of systematic ablation experiments. Experiments proved that in comparison with the negative impacts of introducing the CBAM attention mechanism or the Inner-IoU loss function randomly, a physics-prior-based data augmentation strategy (flipud=0.5 and dynamic mosaic=0.4) has higher engineering value. This strategy did not increase any network parameters but increased the baseline model mAP@0.5 by 96.5 percent and its recall rate by 92.16 percent.

Lastly, a comprehensive closed loop system of visual identification to commercial assessment was developed and deployed. The concept of a diagonal dual-shot multiple-view acquisition plan and the formulation of a non-linear weighted deduction model in conjunction with a logarithmic smoothing device were suggested in order to objectively convert visual defect characteristics into commercial condition ratings (S/A/B/C/D). In terms of engineering, the system uses the ONNX inference engine, FastAPI asynchronous backend and WeChat Mini

Program frontend, which leads to a lightweight full-stack deployment of the system, and a single inference latency of less than 150ms as well as a full-process response of less than 1.5 seconds.

The current research will not only confirm the efficacy of physics-prior-driven optimization in detecting small defects, but also offer a highly feasible and practical automated engineering solution to the condition evaluation standardization in the second-hand electronics market.

Keywords: YOLOv11;Defect detection;Ablation study;Intelligent grading;Data augmentation

目　录

摘　要 ..... **I**

Abstract ..... **II**

第 1 章 绪论 **1**

1.1 课题来源与研究背景 1

1.2 研究目的与意义 1

1.2.1 研究目的 1

1.2.2 研究意义 2

1.3 国内外研究现状 2

1.3.1 工业表面缺陷检测研究现状 2

1.3.2 手机外观瑕疵检测专项研究现状 3

1.3.3 现有研究的不足 4

1.4 主要研究内容与论文组织结构 5

1.4.1 主要研究内容 5

1.4.2 论文组织结构 5

第 2 章 系统分析与设计 **7**

2.1 目标检测技术概述 7

2.1.1 传统目标检测算法及其局限性 7

2.1.2 深度学习目标检测算法的演进 7

2.2 YOLOv11 网络架构与工业适配性解析 8

2.2.1 YOLOv11 核心特征提取模块 9

2.2.2 工业微小目标感知优化机制 10

2.3 典型改进组件在特定场景下的局限性 10

2.3.1 注意力机制的空间表征瓶颈 10

2.3.2 边界框损失函数的几何拓扑边界 11

2.3.3 数据增强的分布漂移与特征破坏 12

2.4 本章小结 12

第 3 章 基于改进 YOLOv11 与多视角的瑕疵评估方法设计 **13**

3.1 手机表面瑕疵数据集构建与质量分析 13

3.1.1 瑕疵类别物理特征定义 13

3.1.2 初始数据集构建与局限性分析 14

3.1.3 数据集全量重构与精准标注规范 14

3.2 面向手机瑕疵的空间对称与动态增强策略 18
3.2.1 垂直翻转的空间各向同性建模原理 18
3.2.2 Mosaic 增强的动态背景复杂度均衡机制 19
3.3 瑕疵多视角识别及评分方法设计 19
3.3.1 “对角两拍法”多视角采集方案 19
3.3.2 结合对数平滑的非线性加权扣分数学模型 21
3.3.3 商业成色等级映射与调价机制 22
3.3.4 视觉证据链局部切图自动生成方法 23
3.4 本章小结 23
第 4 章 算法实验验证与系统实现 25
4.1 实验环境与评价指标 25
4.1.1 软硬件环境配置 25
4.1.2 工业级目标检测评价指标定义 26
4.2 YOLOv11 检测策略消融实验与结果分析 26
4.2.1 基准模型建立与性能参考 27
4.2.2 损失函数替换策略及 Inner-IoU 失效分析 29
4.2.3 注意力机制引入策略及 CBAM 负增益分析 30
4.2.4 数据增强调优实验结果分析 30
4.2.5 最优算法检测性能综合评估 30
4.3 定级系统总体架构与工程化落地 35
4.3.1 FastAPI 异步后端架构与接口设计 36
4.3.2 微信小程序前端交互与状态管理 36
4.3.3 ONNX Runtime 格式转换以及自适应推理引擎 36
4.3.4 缓存控制与服务端资源动态清理机制 37
4.4 系统功能与性能测试 37
4.4.1 软硬件联调与真机测试环境 37
4.4.2 业务流程全闭环功能演示 38
4.4.3 推理延迟与并发响应性能评估 40
4.5 本章小结 41
第 5 章 全文总结与展望 42
5.1 主要研究工作总结 42
5.2 系统局限性与盲区分析 42
5.3 未来研究与迭代展望 43

参考文献 **45**
致谢 **47**

第 1 章 绪论

1.1 课题来源与研究背景

近年来，由于智能手机更新换代速度不断加快，消费者换机速度明显提升，全球二手智能手机市场得到蓬勃发展，在国家大力倡导循环经济背景下，废旧电子产品回收再利用成为热点方向。但作为最大宗消费品，二手手机标准化鉴定体系及分类标准一直未完善。目前，二手手机外观成色主要由人工目测完成，这种方法具有较强主观性、低效性和缺乏统一标准缺点，造成买卖双方信息不对称，易发生争议。

基于深度学习的计算机视觉技术为解决以上问题提供有效解决方案，在近几年目标检测方法特别是单阶段（One-stage）实时检测器已经在工业表面缺陷检测中取得良好效果。Ultralytics 于 2024 年底提出的 YOLOv11[1]，在轻量化模型以及对于小目标识别方面都有很大提升[2]。而在实际应用中，Mohandas[3]等对使用深度学习来进行二手手机翻新评级可行性进行了初步研究。但是目前的研究尚无适应我国二手市场对二手商品需求的统一、成熟的量化评价标准以及适用小规模商家使用的轻量级全栈式解决方案。因此本文提出一种针对二手手机外观缺陷进行自动识别及评级的方法。

1.2 研究目的与意义

1.2.1 研究目的

本文主要目标是解决二手手机交易中外观评估需要人工、标准不一致的问题，在此基础上开发一种可用于中小商家和个人用户的智能化检测及定价工具。主要有以下几点目的：

（1）数据及算法目标：自建手机多材质混合表面瑕疵的数据集，在 YOLOv11 基础上进行一系列的实验研究以找到最佳的数据增强以及特征保持的方法使得模型对于划痕、磕碰、掉漆、裂纹这四种最常见的瑕疵检测 mAP@0.5 达到工业化要求。

（2）评价模型目标：构建一个能够将视觉检测结果转换为商业成色等级的非线性量化定级数学模型，即把瑕疵检测到最终得出一个总的分数之间的关系。

（3）工程落地目标：实现由算法权重到推理引擎工程化过程，在此基础上提出一种基于多视角的图像获取方法，搭建一个包括移动端前端以及异步后端的小而精全栈式产品。

1.2.2 研究意义

本研究的意义主要体现在工程实践与方法论验证两个维度。

从工程技术角度，本文所做工作是针对实际商业应用而进行的研究工作，给二手手机回收商提供一种低成本、高效的外观评估辅助工具。引入定量评级有利于降低经营成本，避免由于个人评判标准不同而导致的交易问题，有利于促进二手电子产品行业的健康发展。

从方法论角度，在此本研究采用严格控制变量的方法，对比分析目前最为常用的注意力机制以及优化损失函数对于手机高反光、小目标情况下的有效范围，在一定程度上指出了某些常用的方法在这类数据上的不足之处。“基于物理先验的数据增强”，对类似工业微小缺陷检测有很好的借鉴意义。

1.3 国内外研究现状

1.3.1 工业表面缺陷检测研究现状

工业表面缺陷自动视觉检测是现代智能制造重要研究内容。陶显等人[4]综述表明，深度学习已经完全代替手工设计特征，而由于速度原因单阶段检测器逐渐成为工业在线应用首选。MDPI Sensors[5]比较也证明 YOLO 系列在工业视觉中占据统治地位。目前，该领域工作正在由识别已有类型缺陷闭合集问题发展到结合多种信息以及对未见过物体进行检测开放集问题[6,7]。

而在实际工业应用中，模型精度以及推断速度之间的权衡始终是一大难题。对于金属或者一些复杂的材料表面，Qiao[8]等认为过高的良品率造成严重的数据极不平衡是影响模型鲁棒性的主要因素。为了解决小样本问题，Jiang Dongnian[9]等通过使用生成的方法（例如 ConSinGAN）增加异常缺陷的数据量进行尝试。另外为了适应工业质检端上设备较低的计算能力， Cheng Keyang[10]等利用中间层的信息传递方式进行知识蒸馏，得

到一种轻量级但是准确率较高的工业品表面缺陷检测方案并且解决了由于模型压缩导致的精度下降的问题。

随着 YOLOv11 出现后，面向具体应用方向的改进层出不穷。王晓婷[11]等人提出基于纹理差异归一化的焊缝缺陷检测方法；戚翔宇[12]等人在 YOLOv11 上加入多头混合自注意力提高印刷电路板细微部分缺陷识别效果；吴旭等使用可变形卷积改善射频部件表面瑕疵识别结果[13]；Wang[14]等人采用 CS-FPN 进行多尺度融合从而增强无人机视角下小目标检测；另外 Wang[15]等人结合边缘计算，将量化后的 YOLOv11 部署到 RK3568 上以证明新型结构具有良好的小型化优势。

1.3.2 手机外观瑕疵检测专项研究现状

对于智能手机外观这种场景而言，检测目标的光学以及材质属性给算法带来很大困难。

对于玻璃面板检测，在 Glass Panel Detection 领域，Han [16]等人建立并公开 SSGD 手机屏幕玻璃数据集，通过对比实验发现基于 CNN 的方法相比于视觉 Transformer 具有更好的工业实用性。但是由于手机玻璃高透明度以及镜子般光泽表面容易造成大量伪影问题。为了解决该类高频反光带来的影响，学者们提出了一系列融合最新注意力机制单阶段检测方法。例如，最近在《Scientific Reports》上报道的研究工作提出 DY-YOLO [17]算法，其使用了一种新颖的方法即动态大核可分离注意力（Dynamic-LSKA），在 SSGD 等手机屏幕公开数据集上有效去除复杂背景反射的影响，提高微小缺陷检测准确率；对于屏幕中小而暗淡的缺陷，还有研究人员 Wu[18]等设计了一种结合多尺度特征以及多个注意力机制的 SSGDD-YOLO 框架，通过对不同特征赋予不同重要程度从而大大减少小目标信息在网络下采样过程中被忽略的概率。在工程应用上，吴建国等[19]、周思瑜等[20]分别针对盖板缺陷以及屏幕 0.5mm 细小划痕利用 YOLOv3 和改进 YOLOv8 对其进行专门提高检测率。而陈湘尹[21]利用 DCGAN 生成大量仿真数据从而提高玻璃缺陷识别效果。

对于多种材质混合及边框识别，在手机金属拉丝或者阳极氧化表面，以及有瑕疵情况下很容易造成误判。Ye[22]等人提出的 YOLO-FIX 采用可变形注意力来解决强光环境下边框胶线缺陷精确定位问题；而 Wu[23]等人提出 MSAdaNet 使用多尺度网络解决混合型缺陷融合过程中出现的语义稀释现象。

从系统层面看，由于手机或者工业边缘端算力有限，因此将高精度视觉模型部署到这些算力受限平台上是目前的研究热点。Zhuo[24]等提出一种称为 LNB-YOLO 轻量级网络，在手机表面缺陷检测上利用剪枝以及知识蒸馏方法，得到了 97.5%mAP 的同时也证明其可以在 RK3568 这类边缘计算设备上进行高帧率工业级应用。类似情况下，Liu[25]等人表明使用轻量级 YOLO 架构以及“云-边”协同方法可以很好地解决在实时路面缺陷检测中嵌入式设备对计算资源的需求问题，对于开发便携式质检具有很好的指导意义；而 Mohandas[3]等人则是最有商业前景的研究者们，他们第一次系统地研究了视觉技术在二手手机翻新及评级方面的作用，发现缺陷种类、大小以及位置是主要考虑因素。

1.3.3 现有研究的不足

从以上文献可见，在针对二手手机综合评价问题上，目前还存在如下一些问题，是本文研究出发点。

（1）专用多材质混合数据集不足。目前的数据集一般只有一种材质（例如只有玻璃材质的 SSGD 数据集[16]），缺少对屏幕、金属边框、后盖有划痕、磕碰、褪色、裂纹等真实二手手机照片的数据集。而且通过 GAN 等生成式方法[26]生成缺陷样本虽然可以增加样本数量，但是无法解决域偏移的问题。

（2）算法模块堆叠场景失配。大量改进工作，例如 Woo[27]等人倾向于添加 CBAM 等注意力机制或者 Zhang[28]等人优化 Inner-IoU 损失函数。但是这些建议忽略了手机高频反光背景对全局池化的影响，也未考虑到特殊情况下非常细长划痕对辅助回归框造成的破坏，缺少对其有效性的充分验证。

（3）数据增强方式不够科学合理。虽然像 Mosaic 这样的数据增强手段已得到广泛使用，但是 Bochkovskiy[29]及最近有关工业微小缺陷检测的研究工作[30]均已表明，原始 Mosaic 随机选取多张图片进行裁剪并拼接的方法很容易使微小的目标发生形变；而过度放大又会使非常细微的目标缩小到网络的感受野以外而被忽略，变成一个孤立的噪声点，在训练过程中造成不良的影响。而在目前的手机瑕疵检测应用上，也几乎很少有人对微小瑕疵的最佳数据增强的比例进行相应的建模以及优化。

（4）检测结果与商业定价存在的矛盾。例如 Mohandas[3]等人所发现，视觉检测与实际定级是有区别的，在现有的大多数研究中，都是只做到“给出检测框”，而没有一个

能够联系到现实中的二手交易行业标准的量化评分方法，不能用于商业定价。

1.4 主要研究内容与论文组织结构

1.4.1 主要研究内容

为了解决目前存在的问题，本文以“数据重构—算法寻优—系统落地”的思路进行，在以下几方面进行了探索。

（1）高质量专有数据集生成。基于二手交易场景下收集并人工精选图片，形成一个包括主流品牌多个种类材质以及四种类型常见缺陷的数据集，在此基础上进行严格的注释规则以及物理增强方法以解决由于原始数据较差而导致模型无法训练的问题。

（2）基于消融实验进行检测方法探索。以 YOLOv11s 为基础模型，在不同的损失函数选择、注意机制加入和数据增强方面进行一系列消融实验，分析某一个模块对于手机瑕疵检测的影响原因，在此基础上利用目标物理先验找到最佳的模型训练配置。

（3）智能定级量化模型设计。根据多视角图像获取情况，提出一种运用对数平滑方法非线性加权扣分模型，在考虑瑕疵类型、相对面积以及视角位置三方面基础上，把底层视觉信息转化为商业成色等级。

（4）轻量化全栈系统工程实现。将最优检测权重转化为 ONNX 格式以建立自适应推理引擎，在 FastAPI 异步框架及微信小程序基础上开发从头到尾外观智能定级应用程序并完成整个流程测试。

1.4.2 论文组织结构

本文共分为五章，各章节内容安排如下：

第 1 章 绪论。介绍课题来源、背景，回顾国内外有关工业缺陷检测以及手机瑕疵评估相关工作进展，指出现有研究成果存在的问题，最后提出本文工作重点和章节安排等。

第 2 章 相关理论及技术背景。介绍目标检测发展概况，分析 YOLOv11 网络结构对于小目标识别作用，同时对注意力模块、损失函数等主要优化手段工作原理及其不足之处进行阐述。

第 3 章 改进 YOLOv11 并结合多角度进行缺陷评价的方法研究。详细介绍本文提出的方案，主要包括自建的数据集全部重制的过程、利用物理先验的空间对称性和添加动态背景的方法，还有加入非线性的平滑处理的基于多个角度的商品打分评级的方法。

第 4 章 算法实验验证及系统实现。进行严格的控制变量消融实验，以数据证明第 3 章提出的优化方法的有效性以及分析无效的方法原因；接着介绍智能定级系统的设计思想、三层架构以及全栈工程化开发过程并且给出系统的测试结果。

第 5 章 总结与展望。对本文所做的主要工作以及所取得的研究成果进行概括归纳，同时指出现有系统存在的不足之处并对其未来的发展方向进行展望。

最后是致谢，表达对指导老师和身边同学的感谢。

第 2 章 系统分析与设计

本章主要为后续算法改进及系统搭建奠定基础，在此简单介绍目标检测发展过程，说明单阶段检测器适合工业应用；其次详细阐述 YOLOv11 网络结构以及其对于小目标识别能力；再者从理论上分析目前常用注意力机制、边界框损失以及生成式数据增强等方法在某些特殊物理环境中所具有的不足之处，以便后续进行相关工作开展。

2.1 目标检测技术概述

2.1.1 传统目标检测算法及其局限性

传统的目标检测主要是基于手工设计特征提取器（例如：HOG、Haar、Gabor 等）以及浅层机器学习分类器（例如：SVM、AdaBoost 等）。而其检测方式一般是在整个图像中以一定步长滑动一个小窗口，然后对这个小窗口内所包含的内容进行两分类判断。

在工业表面缺陷检测领域中，传统的算法存在两大缺陷：第一，人工提取特征完全依靠人的经验和直觉，鲁棒性和泛化能力较差，在手机表面（高反光玻璃、金属拉丝等）复杂材质以及不同的照明条件下容易造成漏检或者误判；第二，滑动窗口穷举所有可能位置的方式使得计算量过大，远远不能满足实际工业生产的要求。

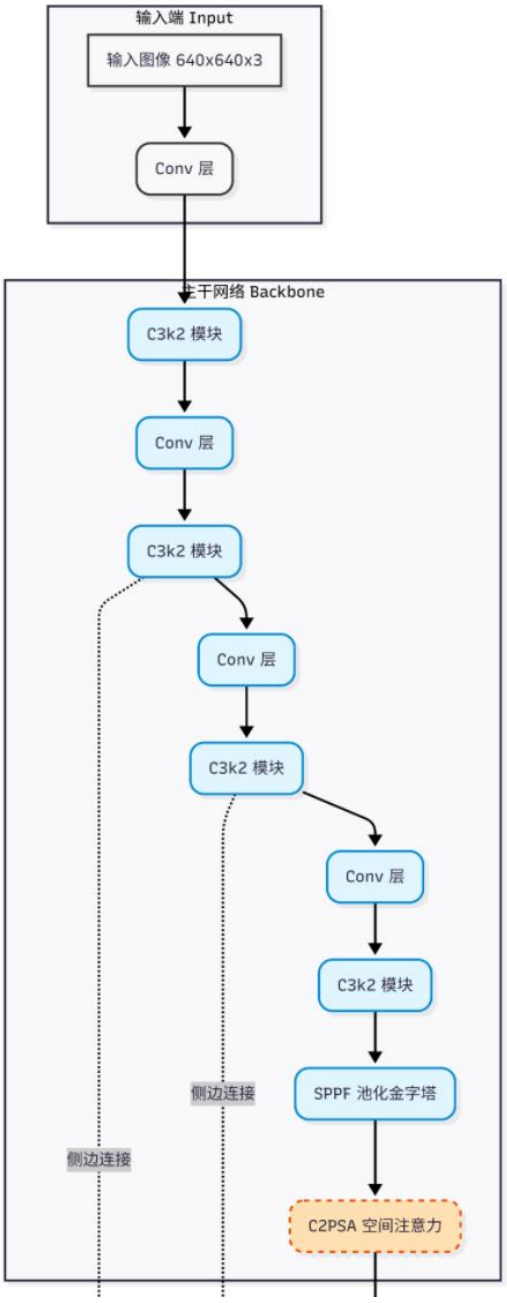
2.1.2 深度学习目标检测算法的演进

随着深度卷积神经网络（CNN）的应用，目标检测发生变革，出现两大类目标检测方法：两阶段（Two-stage）和单阶段（One-stage）。两阶段方法（例如 Faster R-CNN）使用区域提议网络（RPN）生成候选框后再进行二次分类回归，具有较高的准确性但是由于串行处理导致推断时延难以降低。

相比之下，以 YOLO（You Only Look Once）为代表的一类单阶段检测器，把检测问题直接映射到整个图片特征图上进行回归操作，从而实现了一步到位的实时预测。如很多文献报道所描述，在兼顾精度和速度的工业缺陷检测应用上，单阶段检测器已经一统天下。

2.2 YOLOv11 网络架构与工业适配性解析

Ultralytics 于 2024 年底发布的 YOLOv11，在底层网络结构上进行大幅改进，由于采用基于 PyTorch 深度学习框架[31]所具有的动态计算图的特点，在模型大小以及推理速度方面都优于以往所有版本，是目前工业界最常用的骨干网络[1,2]。为更好展示它对于细微缺陷检测的优势，在此根据其内部实现原理简化出 YOLOv11 的整体框架示意图，如图 2.1 所示。



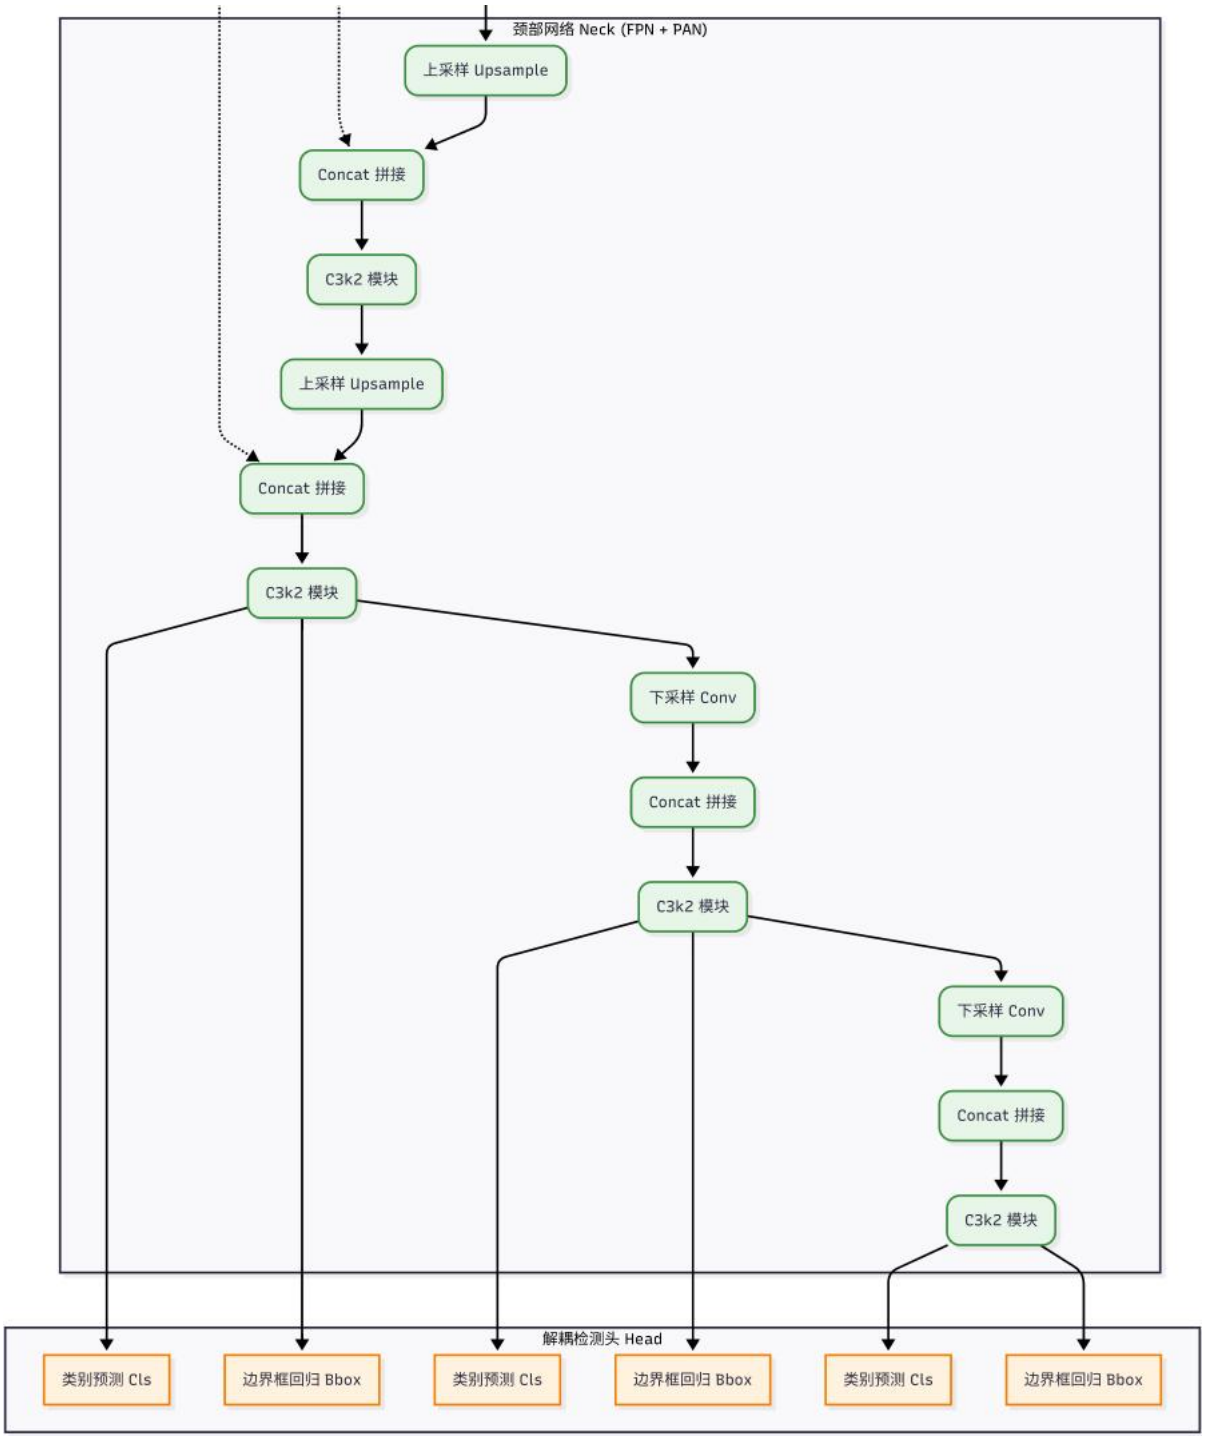


图 2.1 YOLOv11 宏观网络拓扑架构图

2.2.1 YOLOv11 核心特征提取模块

YOLOv11 网络结构仍然采用传统的“骨干网络（Backbone）-颈部网络（Neck）-检测头（Head）”模式，但是加入了三个新模块。

（1）C3k2 模块：是主要的特征学习模块，由于使用较小卷积核进行跨阶段局部连接（局部网络），因此可以在不增加特征图通道数量的情况下显著提高对于局部高频信息（例如边缘纹理等）。

（2）SPPF（快速空间金字塔池化）：位于骨干网络最后，由一系列小尺寸最大池化核串联再连接而成，在几乎不增加额外计算开销情况下实现对不同尺度感受野无损聚合。

（3）C2PSA 模块：在每个卷积块里加入了并行的空间注意力机制，在对特征进行下采样的同时可以让模型自动地对于重要的特征赋予更大的权重。

2.2.2 工业微小目标感知优化机制

对于手机外观检测任务来说，瑕疵（如划痕、掉漆等）一般只占整个图片很小一部分面积。而 YOLOv11 对于工业中小目标识别适应性主要是由于它使用了多种不同尺度特征图组成的金字塔结构。Neck 部分采用一种由上至下以及由下至上两路路径连接的方式即 PANet 连接骨干网络浅层具有丰富空间信息但分辨率较低（有利于小目标准确定位）、深层具有较强语义信息但分辨率较低（有利于类别判断）。有学者发现这种方法对于无人机遥感图像中小目标以及精密工业件中小目标检测都具有非常好的保留特征的能力[14,15]。

2.3 典型改进组件在特定场景下的局限性

目前工业视觉优化的研究中，盲目堆砌“先进算法插件”已经成为一种趋势。但是，每种算法都有它本身适用范围。下面从数学的角度对几种主要改进部分在本文所研究问题中不适合进行详细说明。

2.3.1 注意力机制的空间表征瓶颈

CBAM（Convolutional Block Attention Module）是目前使用最广泛的一种基于通道以及空间的注意力机制，其中其通道注意力子模块的主要思路是利用一个全局平均池化层（GAP）和一个全局最大池化层（GMP），将大小为 H×W 的特征图降维到 HW×1 维度的向量，在此基础上得到各个通道的重要性系数。

对于手机外观瑕疵检测而言，背景部分（例如屏幕反光、金属纹理等）占整个图片99%以上比例，细小划痕激活信号极其微弱，在进行 GAP 操作后，微弱划痕信号被大量背景激活值掩盖（即信号湮灭效应）。尽管 GMP 可以获取最大值或者最小值，但是很容易被手机玻璃上强烈镜面反射高亮区所吸引。由于这个底层数学原理上的问题，常常会造成深层特征流形被破坏，在实际使用中带来较大负面影响。

2.3.2 边界框损失函数的几何拓扑边界

随着目标检测发展，边界框回归损失从最初使用 MSE 演变为 CIoU 等考虑重叠区域、中心点距离以及长宽比形态学损失，为了更快收敛，Zhang[28]等人提出一种 Inner-IoU 损失函数。基本思路是在预测框和真实标注框内生成相应比例较小辅助边界框，并根据该辅助框计算交并比：

$$w_{inner} = w \times ratio, \quad h_{inner} = h \times ratio$$

但是，Inner-IoU 的静态缩放假设对具有极端长宽比的工业瑕疵是不符合实际情况的，在几何拓扑上是有问题的。

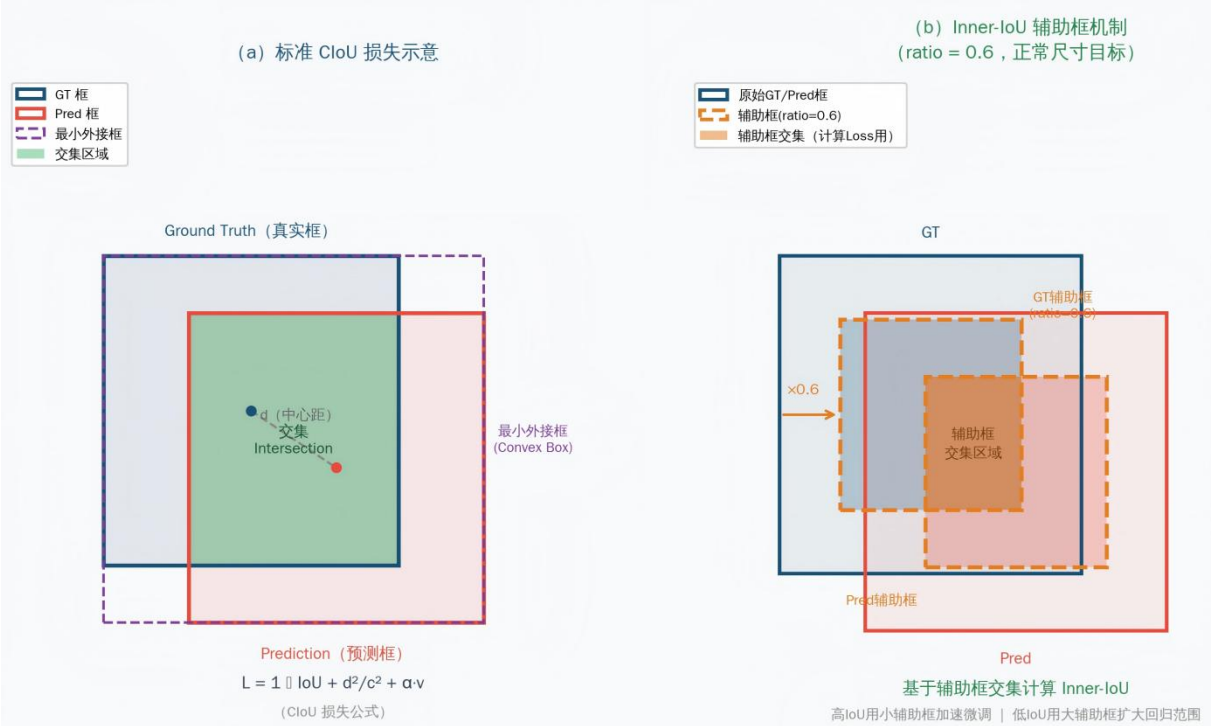


图 2.2 Inner-IoU 辅助边界框机制与极端长宽比失效原理

如图 2.2 所示，在本论文中所使用的划痕目标（scratch）长宽比一般大于 20：1，如

果其较短一边宽度只有 10 个像素点，那么乘以一个较小的比例系数（例如 0.75），得到的辅助框在较短一边上空间范围会变得非常小。由于特征图是在卷积神经网络内部离散表示的，所以这个接近零的较短一边上的空间范围会造成严重的数值截断以及坐标的量化误差，从而使得 IoU 的变化剧烈波动，进而影响到模型对位置的回归效果。

2.3.3 数据增强的分布漂移与特征破坏

为了解决工业缺陷样本不足的问题，一些生成性方法如生成对抗网络（GAN）[26]等也被用来进行数据扩增。虽然生成的方法可以增加视觉上的样本数量，但是由于生成网络中的上采样操作，在频域上，GAN 生成的图片存在着人眼难以察觉、但是 CNN 非常敏感的高频伪影（High-frequency Artifacts）。有文献表明，这些频域上的差别很容易造成合成训练集和真实的物理分布之间存在域偏移（Domain Shift），从而降低模型对于实际复杂环境的鲁棒性[32]。

另一方面，虽然像 Mosaic 这样的复合数据增强方法通过对多张图片进行随机裁剪然后拼接，在训练期间提供大量的不同的上下文并且有助于提高模型鲁棒性[33]。但是就像计算机视觉领域有关小目标数据增强的研究所指出的一样[34]，如果没有对目标尺度施加比例限制，大量使用随机缩放和平移将会使得本来就很小的微小缺陷（比如非常细微划痕）更加缩小，在这个过程中缺陷的重要像素之间连接会被破坏，在网络不断下采样的过程中目标信息消失，从而会导致检测器得不到有效的梯度。因此，数据增强的设计应该基于严格的物理先验以及尺度感知等约束。

2.4 本章小结

本章对目标检测的研究进行总结，并分析出单阶段检测器是实时工业视觉的最优解，在此基础上对 YOLO v11 进行研究，了解其特征金字塔及局部卷积模块对于小目标检测的优势。本章最主要的工作是对 CBAM 注意力机制中的全局池化造成的抑制作用、Inner-IoU 对于极度长宽比瑕疵的退化影响以及大数据增强带来的特征破坏的风险进行了阐述。以上内容不仅可以说明当前通用改进方法在手机外观检测上无法适用的原因，也可以为第 3 章提出的有针对性的数据增强方法以及第 4 章所做的消融实验提供有力支持。

第 3 章 基于改进 YOLOv11 与多视角的瑕疵评估方法设计

本章的目标是建立一个完整的二手手机外观评估的方法论。针对通用工业缺陷检测算法在手机高反光、多材质混合场景下直接应用的局限性，本章首先从底层数据出发，制定了多模态手机瑕疵专有数据集的构建与标注规范；其次，结合手机表面瑕疵的物理空间特性，设计了定制化的空间对称与动态背景增强策略；最后，提出了一种多视角采集与非线性加权扣分相结合的量化评分方法，打通了从视觉特征检测到商业成色定级的逻辑闭环。

3.1 手机表面瑕疵数据集构建与质量分析

在深度学习目标检测任务中，数据集质量决定模型可以学到的能力上线，在公开可获取工业缺陷数据集（如 NEU-DET、PCB 数据集）大多只包含一种材料并且其表面缺陷形态与消费电子产品差别较大情况下，本文为二手手机交易设计专门外观瑕疵数据集。

3.1.1 瑕疵类别物理特征定义

根据对市场上主要二手手机交易网站（如转转、爱回收等）成色鉴定标准的研究，在此将检测对象明确为影响手机商业价值的四种类型较为常见的外观问题。

（1）划痕（scratch）：由硬物刮擦造成的线条型缺陷，有非常大的长宽比（一般大于 20:1）。在光线下由于局部光学畸变而出现，在边缘灰度变化很小的情况下容易被周围的纹理所掩盖。

（2）磕碰（bump）：主要集中在机身边缘或者角落位置，由于受到外界撞击造成的部分区域形状变化或者下陷，一般伴随着该区域材料性质的变化。

（3）掉漆（paint）：表面涂层或者阳极氧化层大块脱落，露出下面颜色，形状不规则，而且容易与手机正常品牌 logo 或者工艺接缝混淆。

（4）裂纹（crack）：玻璃面板（屏幕或后盖）因应力导致的断裂，多呈放射状或网状分布，是造成手机价值大幅贬值的最严重外观损伤。

3.1.2 初始数据集构建与局限性分析

在数据采集初期，本研究尝试了网络爬虫自动化采集方案，但是由于主流电商平台对于反爬虫有严格的限制并且有图片压缩的原因导致效率很低，仅占不到 10%，之后人工筛选出大约 200 张真实场景图作为基础数据集，然后利用 AI 标注平台标注出约 900 张数据。

但是将其初始数据集用于 YOLOv11s 进行初步实验后，在验证集上得到的 mAP@0.5 只有约 50%，不能达到工业要求。为了找出问题所在，在本文中对初始数据集进行了详细的可视化质量检查，发现造成模型效果差的原因主要是因为数据质量问题，如表 3-1 所示。

表 3-1 初始数据集核心质量缺陷分析

问题类型	具体表现	对模型的影响
标注质量低劣	大量标注框越界、偏移、漏标； AI 辅助标注错标率高	模型从未见过真实瑕疵特征， 等同于随机猜测
类别分布严重失衡	bump（磕碰）样本偏少， paint（掉漆）样本几乎缺失	模型偏向多数类，稀缺类 被完全忽视，AP 极低
数据噪声过大	混入大量无瑕疵干净图片、 模糊图片及重复图片	无效特征干扰学习方向， 模型无法收敛至有效表示

分析发现，AI 辅助标注对于有复杂反光背景以及细小划痕的图片容易产生大量的假阳性（误标）和假阴性（漏标）。如果让模型学习到大量的带有噪声甚至是错标坐标的标注信息，则很难学到一个好的特征表示。所以本文提出了一种“舍弃劣质的大规模标注，转而注重高质量的人工标注”的思路。

3.1.3 数据集全量重构与精准标注规范

为了获得高质量的数据集，在此对整个数据集进行重做。先进行严格的样本清洗工作，去除模糊不清、过曝以及标注不清晰的图片，最后选取 481 张具有代表性的不同品

牌、不同材质（玻璃、金属、陶瓷）、不同光照条件下的图片作为样本，这四个样本如图 3.1。

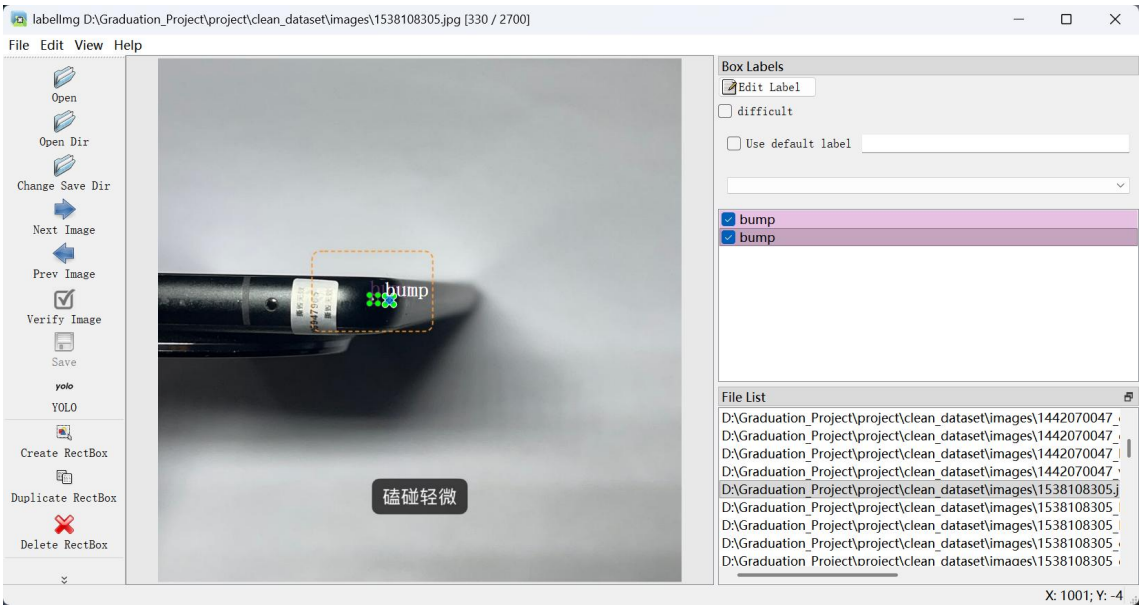


图 3.1 四类典型手机表面瑕疵样本展示

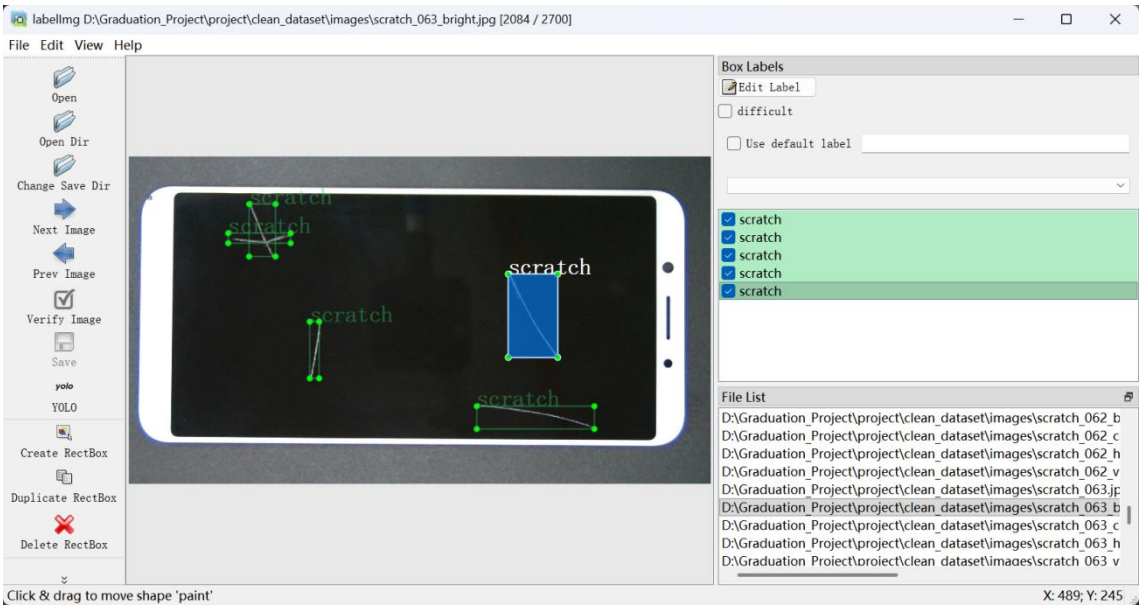
在标注时使用 LabelImg 工具一张一张细致标注，如图 3.2 所示，在此基础上为了满足后面对细微特征的提取制定了较严格的标准：

（1）边界框紧贴约束：标注框必须紧密包围瑕疵边缘，且不能有超过 3px 多余像素，保证目标框与真实物理边界交并比（IoU）很大。

（2）细长目标分离：对于交叉相连的多条细微划痕，使用独立外接矩形框进行标定的方法，不使用大范围一个框包含所有的情况以免引入过多背景像素。



(a)



(b)

图 3.2　LabelImg 人工精细化标注示例

由于选取少量样本导致的问题，在此舍弃易造成较大域偏移（Domain Shift）的基于生成式的增强方法，而选择一种较为温和的物理增强的方法来保证其具有一定的物理真实性。即对于样本较少的磕碰以及掉漆等使用高倍率（约 7.0 倍）的颜色抖动及随机裁剪；而对于划痕及裂纹等则使用亮度或对比度的变化（约 5.0 倍）。最后使得数据集扩

充到 2707 张图片左右，达到较为平衡的状态，增强后数据集的数量如表 3-2 以及图 3.3 所示。

表 3-2 数据增强策略与各类别样本扩充结果

瑕疵类别	原始精选数	增强后数量	主要增强操作	增强倍率
划痕（scratch）	180 张	900 张	翻转、亮度、对比度调整	5.0×
裂纹（crack）	160 张	820 张	翻转、随机裁剪、高斯模糊	5.1×
磕碰（bump）	70 张	490 张	翻转、色彩抖动、随机裁剪	7.0×
掉漆（paint）	71 张	497 张	翻转、亮度调整、对比度增强	7.0×
合计	481 张	2707 张	—	5.6×（平均）



图 3.3 增强后各类别样本数量分布统计

完成数据集构建之后，使用固定随机数种子进行分层随机采样，以 7：2：1 比例划分训练集、验证集及测试集如表 3-3 所示，在二次人工检查过程中发现重建的数据集标注精度在 98%以上，为后续模型的可靠训练奠定了数据基础。

表 3-3 手机表面瑕疵数据集划分统计

子集	划痕（张）	裂纹（张）	磕碰（张）	掉漆（张）	合计（张）
训练集（70%）	630	574	343	348	1895
验证集（20%）	180	164	98	99	541
测试集（10%）	90	82	49	50	271
合计	900	820	490	497	2707

3.2 面向手机瑕疵的空间对称与动态增强策略

为了提高目标检测的效果，在增加目标检测模型复杂度的同时，过度使用复杂的注意力机制或者损失函数会导致不良的效果。本文以手机表面缺陷的真实物理特性为基础，在 YOLOv11 中对数据进行读取的过程中，提出了一种专门的空间对称以及动态背景的数据增强方法，加入物理先验增强模型鲁棒性。

3.2.1 垂直翻转的空间各向同性建模原理

手机表面的划痕以及裂缝从几何上看都是一种典型的各向同性（Isotropic）现象，也就是说这些缺陷出现的方向是没有任何规律可循的。但是在实际成像过程中由于拍摄角度固定，所以造成样本集中缺陷的方向是有偏向性的。

为了去除这种偏差，在训练流程上添加概率为 0.5 垂直翻转（Vertical Flip，flipud=0.5）。这个操作的本质就是让网络在学习特征时获得对于 y 轴方向不变性。如果网络见到正放和倒置的缺陷图像，那么它就不可能再基于缺陷在图片上的绝对位置以及绝对朝向去学

习卷积核，而只能关注那些更加基本的低层次纹理梯度以及边缘锐利程度等信息。这样做的好处是在不增加网络复杂度情况下大大提高了网络对于不同放置方式设备识别能力。

3.2.2 Mosaic 增强的动态背景复杂度均衡机制

手机外观材质（例如金属拉丝边框、高反光玻璃面板等）形成非常有干扰性的高频背景，在传统 Mosaic 增强方法中，采用随机选择四张图片进行缩放后拼接的方式可以使网络在一个前向传播的过程中学到大量的跨区域背景信息从而提高其鲁棒性。

但是，对手机屏幕细小划痕等极小目标而言，一般 Mosaic 设置（例如比例为 1.0）会使目标区域在拼接缩放时被过分缩小，甚至小于骨干网络深层感受野，造成特征碎片化（Feature Fragmentation）以及大量漏检。

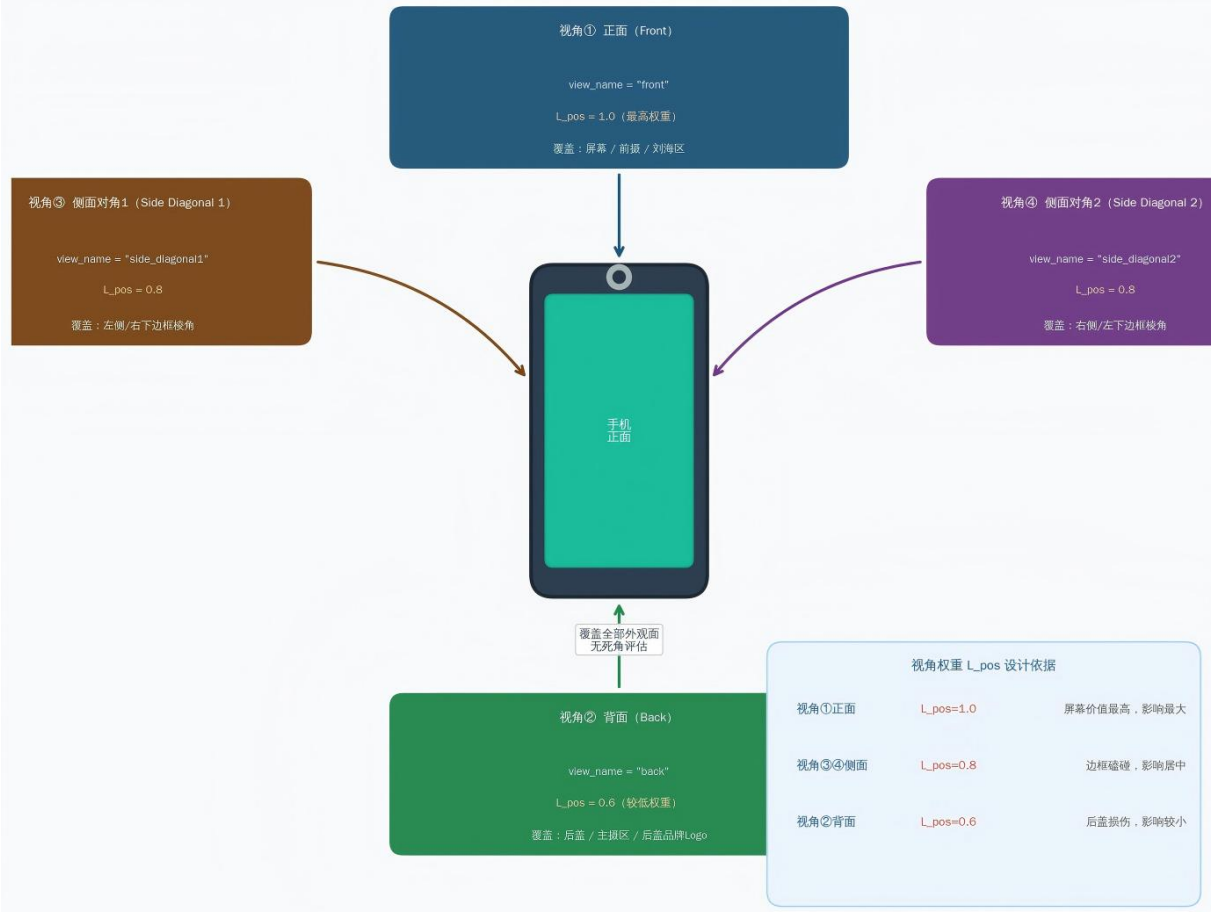
为了解决“背景抗噪”与“小目标保留”的矛盾问题，在实验中选择 mosaic=0.4 作为折中方案，即在训练时 50%概率使用高难度拼接图来提高模型鲁棒性的同时又有 50%概率使用原有大小单张图片保证对细微物体识别能力，这样的方式更符合手机上多种材料混合物体检测的需求。

3.3 瑕疵多视角识别及评分方法设计

深度学习算法直接输出的通常是瑕疵类别与边界框坐标，而实际商业交易需要的是具有指导意义的量化成色等级。本节设计了一套连接“计算机视觉特征”与“商业定级标准”的算法引擎。

3.3.1 “对角两拍法”多视角采集方案

为解决单视角拍摄易造成角落缺陷忽略问题以及全景扫描设备昂贵价格，在此提出一种简单易操作“对角两拍法”四个视角拍照方式，“对角两拍法”即需要四个固定角度进行拍照：正面（front）、背面（back）、侧面对角线 1（side_diagonal1，包含左上到右下的棱角）与侧面对角线 2（side_diagonal2，包含右上到左下的棱角），具体拍摄角度和手法如图 3.4 所示。



(a) 对角两拍法平面展示图



(b) 对角两拍法正面拍摄



(c) 对角两拍法侧面对角线 1 拍摄



(d) 对角两拍法侧面对角线 2 拍摄　　(e) 对角两拍法背面拍摄

图 3.4 “对角两拍法”多视角采集方案及权重分配

各个角度的商业权重L_{pos}根据其对整机价值的影响程度差异化设定：屏幕正面最重要，定为 1.0；侧面边框容易出现无法修复的划痕，定为 0.8；背面后盖影响不大，定为 0.6。该方案以最少的拍摄步骤实现了整机外观面的无死角覆盖。

3.3.2 结合对数平滑的非线性加权扣分数学模型

根据上述多视角检测所得瑕疵集，本文提出了一种结合瑕疵种类（Severity）、相对面积（Area Ratio）以及位置归属（Position）三者进行加权扣分的方法来获得一个公平合理的百分制评分的方法，即：

$$\text{Score} = 100 - \sum_{i=1}^{n} (W_{type}^{(i)} \times \log_{10}(1 + S_{area}^{(i)} \times 1000) \times L_{pos}^{(i)})$$

公式中参数定义如下：

（1）类型惩罚基数 W_{type} ：根据不同的缺陷对硬件寿命以及美观造成的不同程度影响给予裂纹(50) > 磕碰(15) > 掉漆(10)> 划痕(5)。

（2）面积对数因子 S_{area} ：YOLO 所得到的边界框像素面积占整个图像面积的比例。引入以 10 为底的对数函数 $log_{10}(1+x)$ ，原因在于模拟人眼对于瑕疵感知是非线性的“边际厌恶感递减”，即小瑕疵面积增大会带来较大的扣分增长，而大瑕疵面积增大带来的扣分会变得缓慢，这样可以避免因为检测到一个极大目标而使得总评分过低（出

现负值）的情况发生。

（3）视角位置权重 L_{pos} ：对应前文所述的视角权重系数。



图 3.5 结合对数平滑的非线性定级扣分算法演算

3.3.3 商业成色等级映射与调价机制

得到百分制分数之后，系统利用一定阈值映射规则将其转换为国内二手市场上常见的 S/A/B/C/D 五个成色等级以及每个等级所对应一个浮动保值率（Discount Rate）。成色等级与保值率的映射关系如表 3-4 所示。

表 3-4 多视角综合得分与商业成色等级映射规则

等级	行业俗称	综合得分区间	保值率	典型状态	示例扣分场景
S 级	99 新	score ≥ 98	92%	近乎完美无	无或极微小划

等级	行业俗称	综合得分区间	保值率	典型状态	示例扣分场景
				划痕	痕
A 级	95 新	90 ≤ score < 98	85%	轻微使用痕迹	1～2 处细小划痕
B 级	9 成新	75 ≤ score < 90	70%	中度使用痕迹	多处划痕或掉漆
C 级	8 成新	60 ≤ score < 75	50%	明显外观损伤	磕碰变形或大划痕
D 级	残次品	score < 60	30%	严重损坏	存在裂纹或屏碎

在实际使用场景下，引入了动态调价机制（Est_Price = Base_Price × Discount_Rate）。检测系统仅负责输出客观的折旧比例，最终的预估回收价由用户输入的实时新机市场基准价（Base_Price）动态计算生成，从而实现了底层算法与前端业务分离。

3.3.4 视觉证据链局部切图自动生成方法

为保证定级结果公开、可追溯，本方法集成了局部特征自动裁剪逻辑。基于 YOLOv11 输出的边界框坐标 $(x_{min}, y_{min}, x_{max}, y_{max})$，算法在原始高分辨率图像上执行向外扩展 20 个像素点的 Padding 操作，生成包含瑕疵主体及其上下文环境的局部特写切图。这些切图在输出定级报告时作为“视觉证据链”同步展示，显著提升了机器定级结果对终端用户的说服力与公信力。

3.4 本章小结

本章详细介绍了二手手机外观瑕疵智能评估系统的实现过程。一方面由于缺乏通用的数据集，在进行仔细的数据清理和标注之后自制一个由 2707 个多模态组成的高质量瑕疵数据集；另一方面由于瑕疵具有物理上的随机性和手机表面的高反光率，在此基础

上提出了垂直翻转以及最优比例 Mosaic 的动态增强方法；同时提出了一套包含多视角采集、对数平滑非线性扣分以及动态定价的综合评分方法来解决底层计算机视觉问题与上层商业评级要求之间的矛盾。本章的设计方案将在第 4 章的消融实验及系统实现中进行全面验证。

第 4 章 算法实验验证与系统实现

本章主要对第 3 章所提瑕疵评估方法进行有效性验证以及其工程化实现的过程。首先通过大量消融实验从客观上比较不同损失函数选择、注意力机制添加和数据增强优化对于 YOLOv11s 基线模型的影响并分析其中原因；其次，在最优算法基础上介绍系统整体三层结构以及全栈式开发工作内容；最后通过对功能及性能测试来证明该系统可以应用于实际生产环境中使用。

4.1 实验环境与评价指标

4.1.1 软硬件环境配置

为了保证每组消融实验的一致性和可比性，在本论文中所有模型训练及测试都在同一套软硬件条件下完成。所有实验使用相同训练次数（100 epochs）、批大小（batch=16）以及带有余弦退火的学习率策略（lr0=0.01）。具体配置如表 4-1 所示。

表 4-1 实验软硬件环境配置

配置项	配置内容
硬件平台	NVIDIA GeForce RTX 5070 Ti（12GB VRAM）
深度学习框架	PyTorch 2.8.0
目标检测框架	Ultralytics 8.4.37
操作系统	Windows 11 64 位
开发环境	Python 3.9 / VS Code
CUDA 版本	CUDA 12.x / cuDNN 9.x
训练轮次	100 epochs（每组实验统一配置）
批次大小	batch=16
基础学习率	lr0=0.01，余弦退火调度

4.1.2 工业级目标检测评价指标定义

本研究以目标检测领域常用的标准来进行评价模型的效果，主要采用的是精确率（Precision, P）、召回率（Recall, R）以及平均精度均值（mAP@0.5）。

（1）精确率（Precision）：评估模型预测为正的样本中，实际为正样本的比例。

$$Precision = \frac{TP}{TP + FP}$$

（2）召回率(Recall)：评估所有真实正样本中，被模型正确检出的比例。

$$Recall = \frac{TP}{TP + FN}$$

（3）平均精度均值（mAP@0.5）：以交并比（IoU）阈值为 0.5 作为正负样本判定标准，计算各类别精确率-召回率曲线（P-R 曲线）下的面积（AP）后取算术平均值，是衡量检测系统综合性能的最核心指标。

$$mAP@0.5 = \frac{1}{N}\sum_{i-1}^{N} AP_i$$

在二手手机瑕疵检测等工业应用场景中，漏检一块严重裂纹的商业代价远大于误报一次轻微划痕。因此，在评估不同算法策略的优劣时，本研究将在关注 mAP 综合指标的同时，对召回率（Recall）指标给予更高的评估权重。

4.2 YOLOv11 检测策略消融实验与结果分析

为了更好地分析每一种优化方法对于最终检测效果所起的作用，在这一部分进行了一个有十个不同控制变量的消融实验。包括边界框损失权重调整、Inner-IoU 损失引入、CBAM 注意力机制加入以及随机数据增强。所有这些实验的结果总结见表 4-2。

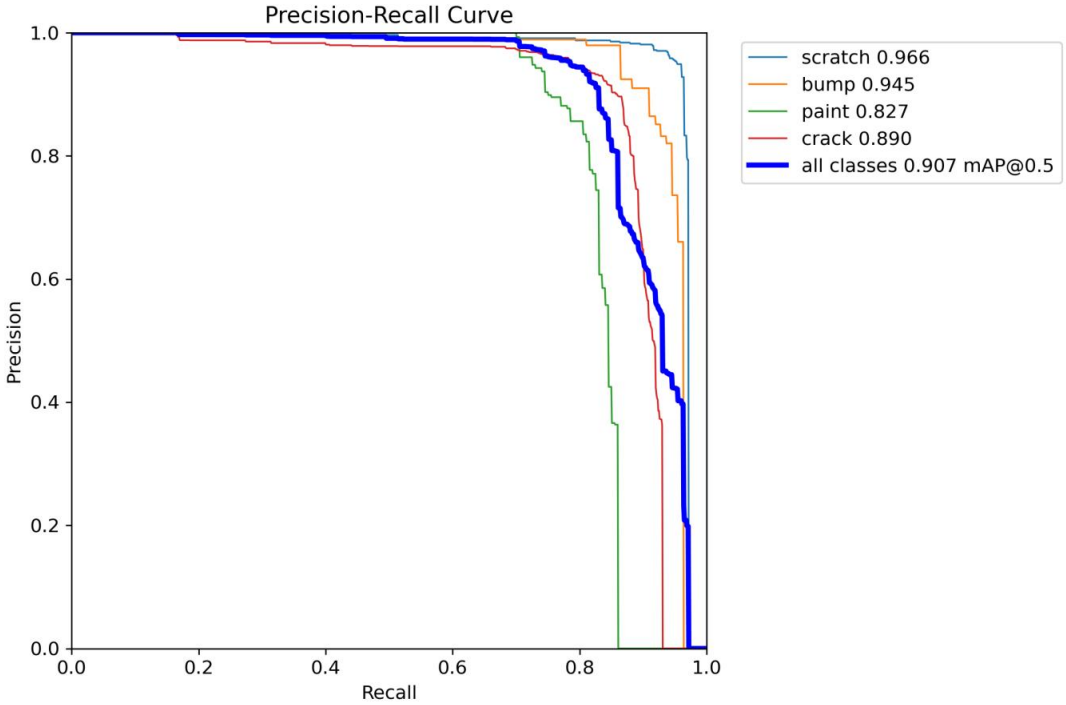
表 4-2 目标检测策略系统性消融实验配置与性能对比

编号	实验名称	box	Inner-IoU (ratio)	CBAM	imgsz	mosaic	flipud	mAP @0.5	变化幅度
1	基线模型 Baseline	12.0	×	×	640	0.00	0.00	0.907	—
2	降低 box 权重	7.5	×	×	640	0.00	0.00	0.899	−0.8%
3	仅 Inner-IoU	12.0	√ (0.80)	×	640	0.00	0.00	0.902	−0.5%
4	Inner-IoU + 降 box	7.5	√ (0.75)	×	640	0.00	0.00	0.893	−1.5%
5	Inner-IoU + 多参数	12.0	√ (0.80)	×	800	0.50	0.00	0.905	−0.2%
6	改进基线（最优）	12.0	×	×	640	0.40	0.50	0.965	+5.8%
7	Inner-IoU + flipud	12.0	√ (0.70)	×	640	0.40	0.50	0.954	+4.7%
8	Inner-IoU + CBAM	12.0	√ (0.70)	单层	640	0.40	0.50	0.913	+0.7%
9	仅 CBAM（单层）	12.0	×	单层	640	0.00	0.00	0.877	−3.3%
10	仅 CBAM（多层）	12.0	×	多层	640	0.00	0.00	0.868	−4.3%

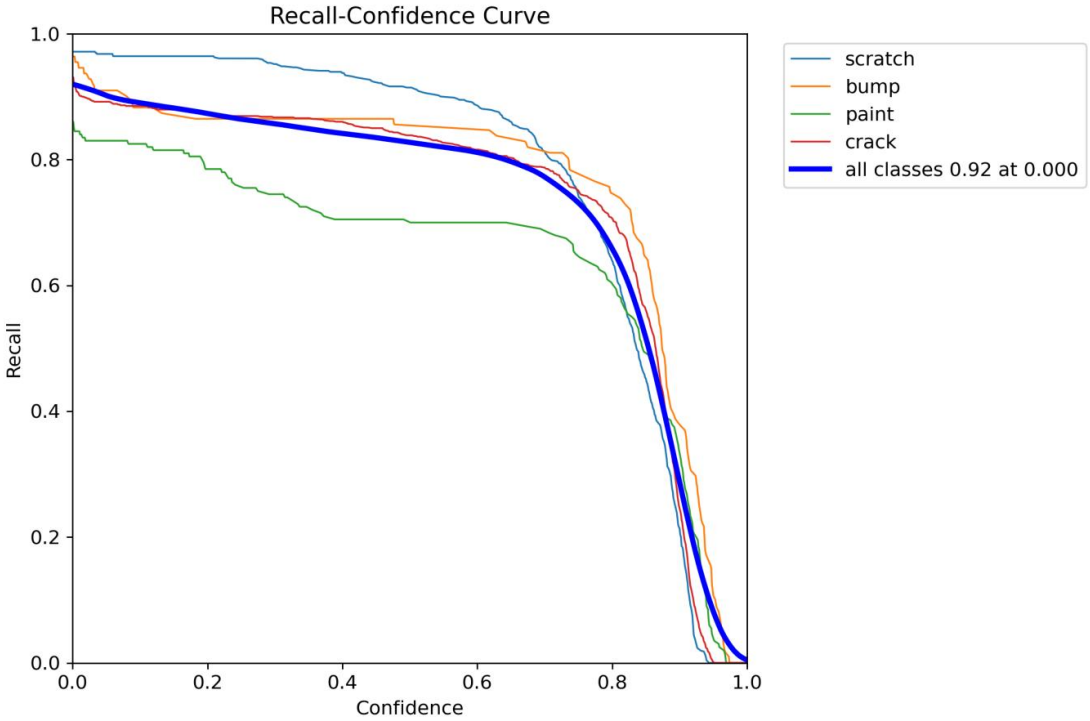
4.2.1 基准模型建立与性能参考

以 YOLOv11s（Small 版本）为基础，在没有任何附加优化手段的前提下进行基础训练，即不使用翻转以及 Mosaic 的数据增强方法（flipud=0.0, mosaic=0.0）。经过 100 轮迭代，基准模型各项损失平稳收敛，在验证集上取得的性能指标为：mAP@0.5 = 0.907，Precision = 94.36%，Recall = 84.78%。如图 4.1 所示。

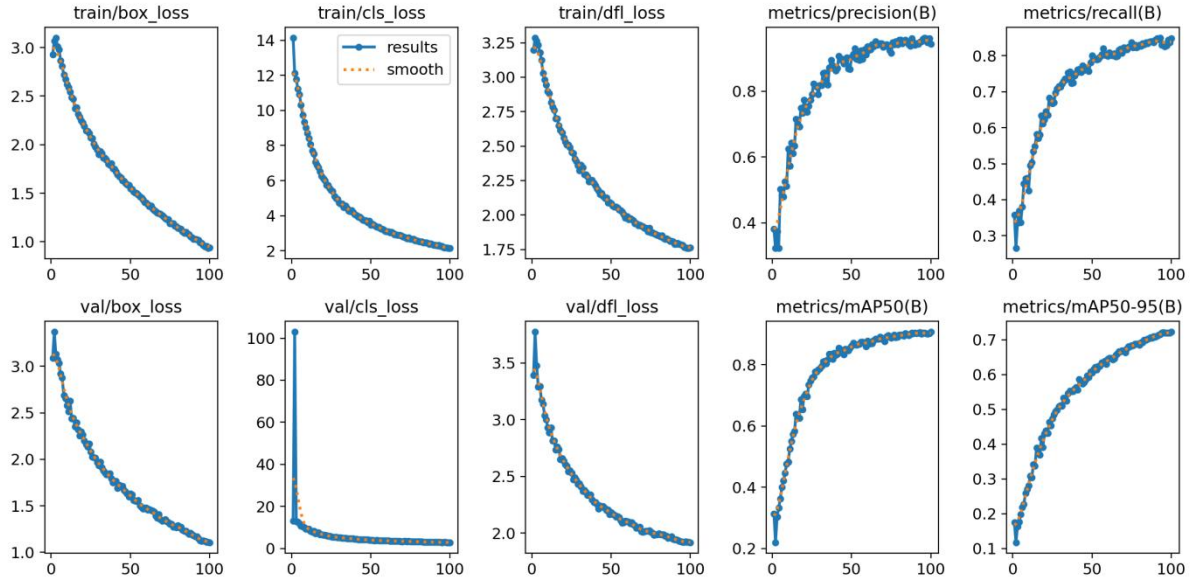
这说明在第 3 章所建立的数据集是有效的（模型成功突破了初始低质数据下约 50% 的性能瓶颈）。以实验 1 作为基线模型，后续实验将逐一验证各项改进策略。



(a) 基准模型（Exp 1）P-R 曲线



(b) 基准模型（Exp 1）R-C 曲线



(c) 基准模型（Exp 1）训练过程各项指标综合曲线

图 4.1 YOLOv11s 基准模型训练收敛过程与评估曲线

4.2.2 损失函数替换策略及 Inner-IoU 失效分析

在微小目标检测任务中，边界框的定位精度通常对模型整体性能影响显著。本组实验首先探讨了定位损失权重的调节以及 Inner-IoU 辅助框机制的适用性。

实验表明，减小 box 损失权重（从 12.0 到 7.5）会使 mAP 降低 0.8%，说明强烈的定位指导对检测细微划痕是非常必要的。而如果保持较高的 box 权重不变，在此基础上增加 Inner-IoU（ratio=0.80）损失，则不会使 mAP 提高，甚至略有下降至 0.902。

通过对于失败样本进行可视化分析，得出 Inner-IoU 在本场景下失败原因有两个方面。

（1）极端长宽比造成辅助框退化。划痕（scratch）这一类型的目标具有很大的长宽比，可以达到 20:1，在这种情况下，以固定的全局比例（ratio）缩放得到辅助边界框，其短边宽度在数值计算中会退化至趋近于 0，产生极不稳定的极小 IoU 值，引发反向传播时的梯度震荡。

（2）静态比例因子与多种不同类型的缺陷之间的冲突。该数据集中存在点状（磕碰）、线状（划痕）、面状（掉漆）等各种不同的缺陷类型，固定 ratio 对于不同类型的效果不尽相同，Inner-IoU 对划痕定位的微弱帮助被其对掉漆类别回归造成的干扰所抵

消，导致整体指标下滑。

4.2.3 注意力机制引入策略及 CBAM 负增益分析

对于背景干扰问题，在 YOLOv11s 骨干网络（Backbone）末尾以及颈部网络（Neck）特征融合处加入 CBAM（卷积块注意力模块）。

但是，单层或多层 CBAM 引入都带来较大的系统性负增益，在多层 CBAM 情况下甚至使 mAP 下降 4.3 个百分点至 0.868。这主要是由于：

（1）全局池化对微弱信号的湮灭作用。手机表面划痕在图像中所占比例很小（不到 1%）。而 CBAM 的通道注意力机制使用全局平均池化（GAP）操作，当极小的高频瑕疵信号与大面积的高反光背景信号进行平均压缩时，目标特征被彻底稀释，导致网络将注意力权重错误地分配给了高反光的干扰背景。

（2）深层特征流形的表征破坏。在网络深层特征已被高度压缩阶段，在其中加入非线性重参数化操作会破坏网络对细小纹理已建立的稳定梯度路径。

4.2.4 数据增强调优实验结果分析

当以上网络结构以及损失函数改进策略均未达到预期效果后，本研究转向基于物理先验的数据增强策略。

实验表明，采用组合方式使垂直翻转（flipud=0.5）以及 Mosaic 拼接（mosaic=0.4），在无需增加额外网络参数，也不需要改变底层计算图情况下，可以取得很大提升。这说明第 3 章提出的“空间各向同性建模”及“动态背景复杂度均衡”的有效性。相比于堆砌各种复杂的算法插件，针对特定物理场景定制的数据增强策略展现出了更高的工程价值。

4.2.5 最优算法检测性能综合评估

确定最优的数据增强方法（flipud=0.5 以及 mosaic=0.4）之后，在这种方法基础上训练得到的模型作为本文所用的最终检测算法（Exp 6）。相比于未进行优化的基本模型，在所有重要的指标上都有全面显著的提升，其中 mAP@0.5 由原来的 0.907 提高到 0.965（增加 5.8%），更重要的是召回率（Recall）由原来的 84.78%上升到 92.16%（增加 7.38%）。而在真实二手手机工业质检过程中，残次品漏检所带来的商业风险远远大于轻微瑕疵误

判造成的影响，该召回率的大幅提升从根本上降低漏检率，具有高工程实用性。

表 4-3 最优模型各类别检测性能对比

瑕疵类别	基线 AP@0.5	最优 AP@0.5	提升幅度	工业含义
划痕（scratch）	96.6%	97.2%	+0.6%	细线状瑕疵定位更精准
裂纹（crack）	89.0%	97.8%	+8.8%	裂纹检出率大幅提升
磕碰（bump）	94.5%	97.1%	+2.6%	凹坑类目检测稳定
掉漆（paint）	82.7%	93.9%	+11.2%	掉漆识别提升最显著

根据表 4-3 中分类细分为，掉漆（paint）类别 AP 提升最大（+11.2%），说明 Mosaic 增强确实效解决了掉漆边缘特征与背景复杂纹理的混淆问题；裂纹（crack）类提升 8.8%，说明空间翻转策略消除了模型对瑕疵扩展方向的感知偏置。

为了更进一步测试这个最优模型的鲁棒性，本研究进一步探究了其在训练与验证阶段的全维度评估指标曲线。

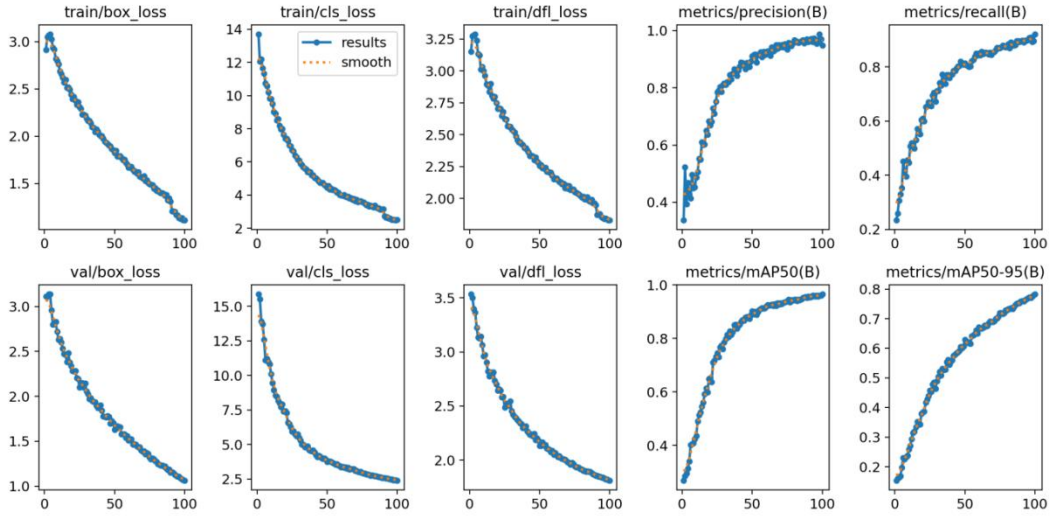
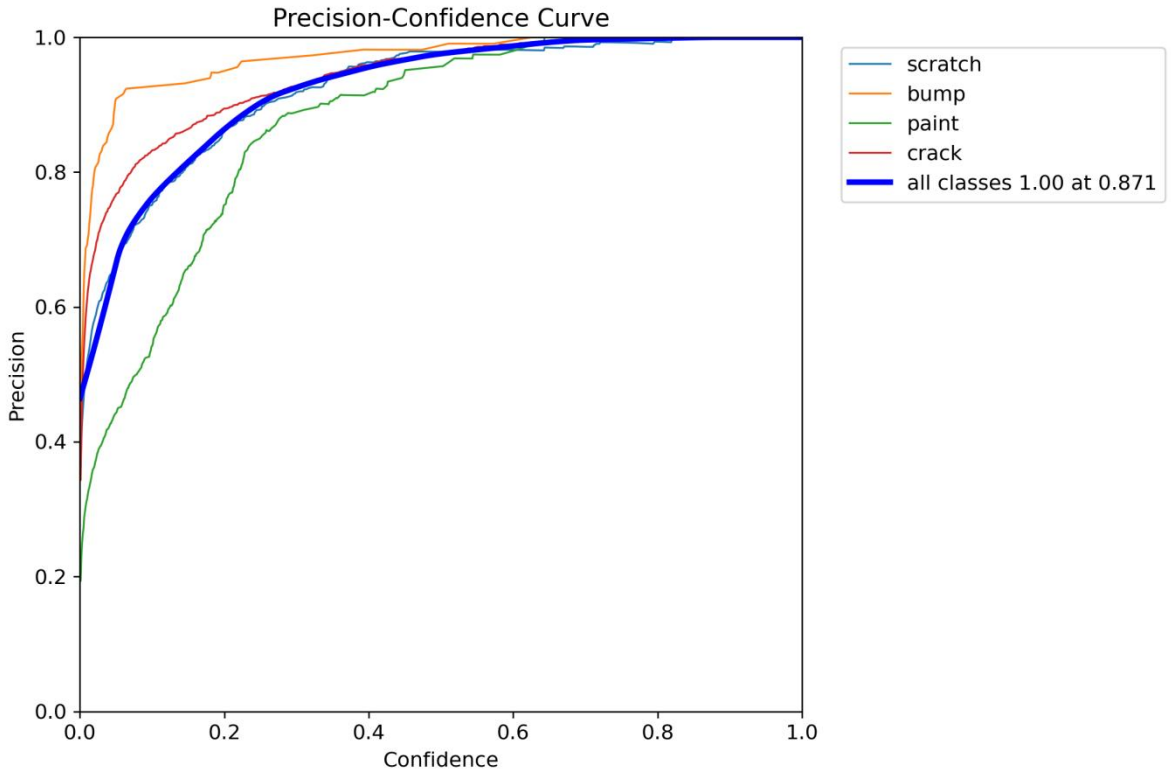
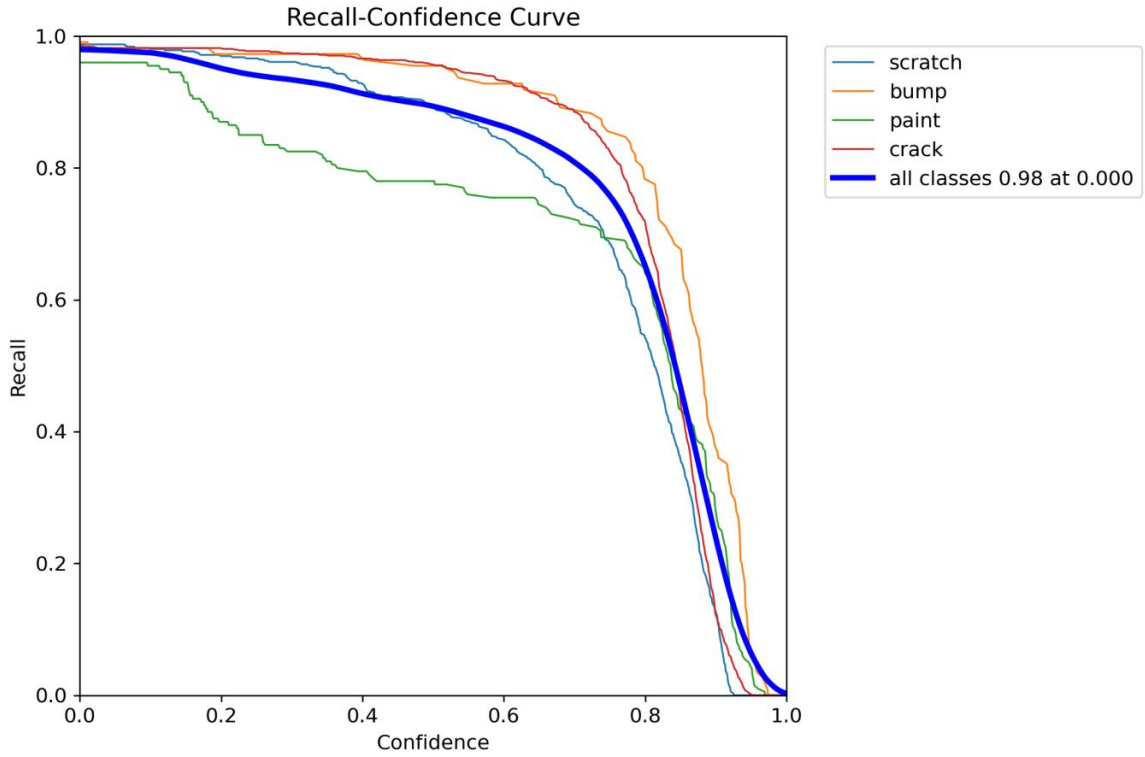


图 4.2 最优模型 100 轮次训练过程中各种损失与评估指标综合曲线

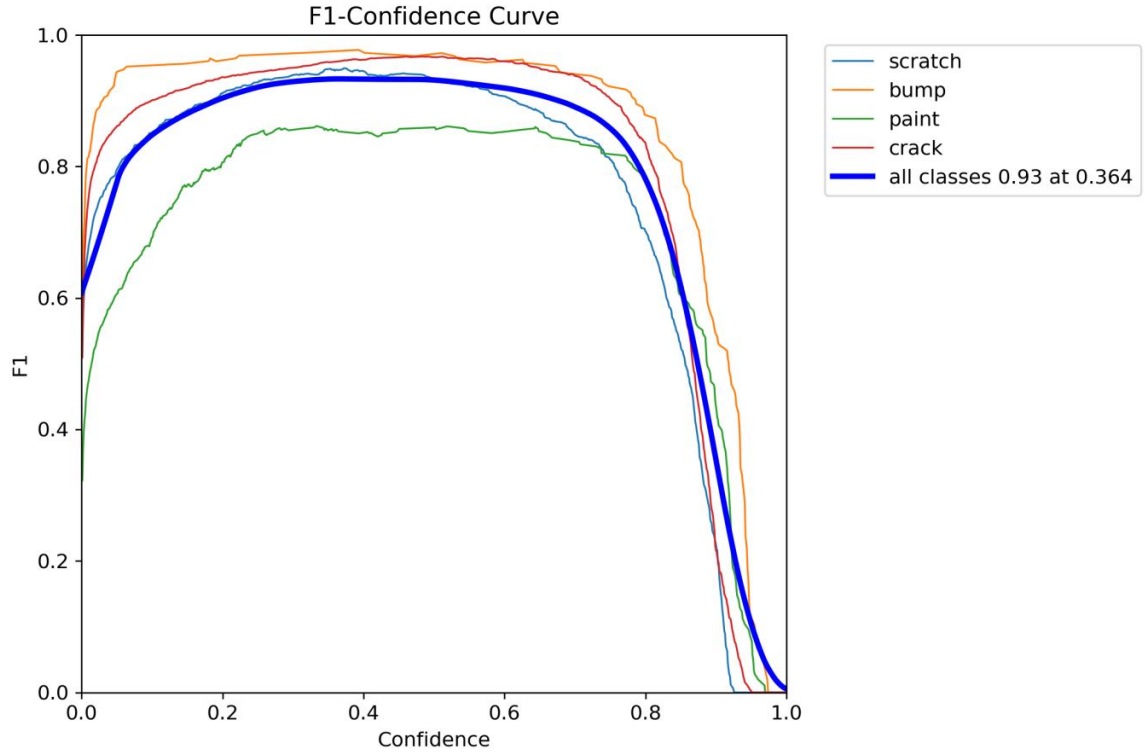
如图 4.2 所示的训练过程综合曲线（results）显示，模型在 100 个 Epoch 的训练周期内具有良好的收敛性。边界框损失（box_loss）、分类损失（cls_loss）以及分布焦点损失（dfl_loss）在训练集和验证集上都呈现逐渐减小的趋势，无梯度震荡造成过拟合（Overfitting）。而 mAP@0.5 和 mAP@0.5:0.95 在第 50 轮之后趋于平稳，说明模型已经很好地拟合训练集的数据。



(a) P 曲线


Recall-Confidence Curve
Recall
Confidence
scratch
bump
paint
crack
all classes 0.98 at 0.000

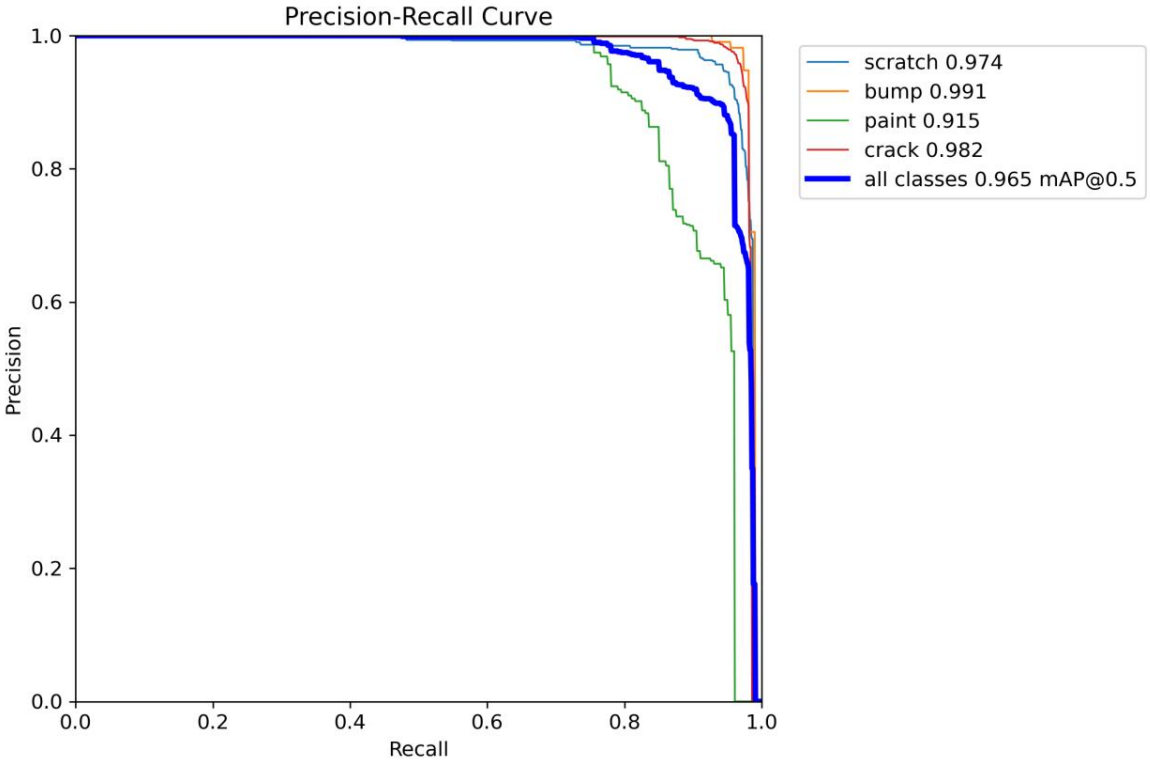
(b) R 曲线


F1-Confidence Curve
F1
Confidence
scratch
bump
paint
crack
all classes 0.93 at 0.364

(c) F1 曲线

图 4.3 最优模型置信度相关评估曲线

目标检测的实际工程表现高度依赖于置信度阈值的设定。从图 4.3 可以看出，置信度-Precision 曲线以及置信度-Recall 曲线表明，最优模型在极宽的置信度阈值区间内维持了优异的指标表现。特别是在综合反映模型平衡能力的 F1-Score 曲线（Precision 与 Recall 的调和平均数）中，全类别平均 F1 分数在最佳置信度节点处达到峰值。这意味着这个模型在实际应用中无需通过极端调低阈值来换取召回率，天然具备“低误报、低漏检”的双重优势。



(a) P-R 曲线



(b) 归一化混淆曲线

图 4.4 最优模型准确率-召回率（P-R）曲线以及归一化的混淆矩阵。

最后如图 4.4 所示，在最优模型的基础上，通过该模型的精确率-召回率（P-R）曲线以及归一化的混淆矩阵也可以看出其具有较高的鲁棒性的边界。P-R 曲线显示了当召回率大于等于 0.90 时，模型仍能保持很高的精确率边界，曲线下面积（AUC）饱满。

在混淆矩阵的类间交叉数据中有很高的判别纯度：矩阵对角线上的真正率均维持在高位。尤其是最容易在特征层出现混淆的外观轻微损坏（划痕 scratch）和结构严重损坏（裂纹 crack）之间互相误分类的概率被完全抑制到 0.00。这种对本质缺陷严重程度的绝对精准划定，保障了分类输出的数据纯度，从而也为基于瑕疵类型的非线性加权的商业评级算法奠定了坚实的基础。

4.3 定级系统总体架构与工程化落地

为了进一步检验该方案在实际应用中是否可行，本节实现了从训练权重到轻量级端到端系统的全栈工程开发。

如图 4.5 所示，本系统采用的前后端分离三层架构。展示层使用微信小程序实现，以方便二手交易移动端低门槛使用；业务逻辑层使用 FastAPI 异步框架负责算法调度以及定级计算；数据层使用本地文件系统加上自动清理方式管理。

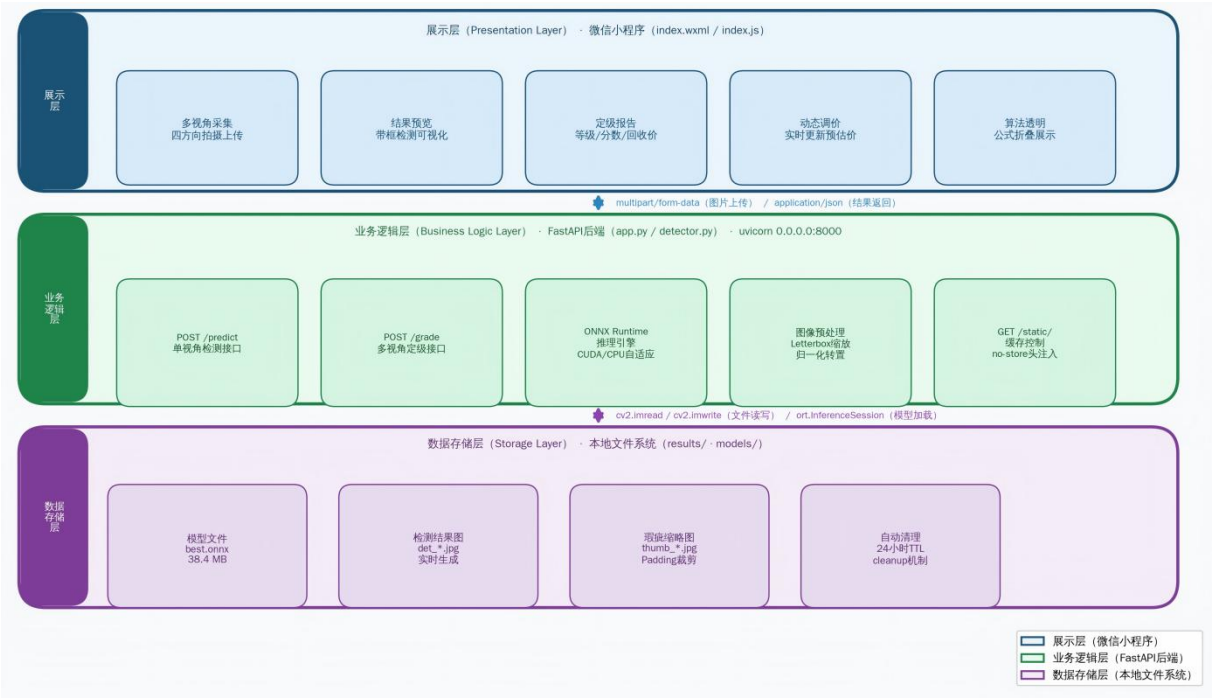


图 4.5 定级系统三层架构设计图

4.3.1 FastAPI 异步后端架构与接口设计

后端服务基于 Python 开发并使用 FastAPI 框架中自带异步能力(asyncio)提高大量请求时 I/O 效率问题。整个应用提供两个 RESTful API 给外部调用：

（1）/api/v1/predict：接收前端上传单视角图片流，调用推理引擎并返回 JSON 格式检测坐标以及带有标注框可视化图片。

（2）/api/v1/grade：接收一个包含了四个角度汇总信息的 Payload 以及一台新机的价格作为参数，调用第 3 章中设计的非线性加权定级算法，输出结果为总分、品相等级以及预估回收价格。

4.3.2 微信小程序前端交互与状态管理

前端应用舍弃复杂的 Web framework，使用微信小程序原生开发。页面交互是“操作

提示-即时反馈”，有基准价输入区域、四个方向格子拍照区域以及定级报告展示区域。

在工程上，为了解决多视角异步上传导致的数据覆盖问题，在前端对全局状态(Page.data.allResults)使用以视角唯一性（例如 view_name="front"）为键值的字典进行存储。这样即使因为网络延迟或者用户连续点击快拍造成多个视角同时上传，每个视角的检测结果也会正确、独立地保存到相应位置，从而保证最后定级汇总的结果是正确的。

4.3.3 ONNX Runtime 格式转换与自适应推理引擎

为了减少对于庞大的 PyTorch 运行时的需求以及提高推理的速度，在完成模型训练之后将得到的最佳模型 best.pt 权重转化为更为通用的 ONNX（Open Neural Network Exchange）格式，其大小为 38.4MB，在进行转换时使用了固定的输入大小（1×3×640×640）以及计算图融合（Graph Fusion）以降低不必要的内存搬运开销。

同时，后端集成了硬件自适应推理引擎，在程序启动时，引擎会首先尝试使用 CUDAExecutionProvider 进行探测；如果未检测到 NVIDIA 显卡或者驱动版本不匹配的情况，则会平滑地切换到 CPUExecutionProvider。这样可以使得该程序既可以运行在高性能服务器上提供很低延迟，也可以在一般的电脑上正常使用。

4.3.4 缓存控制与服务端资源动态清理机制

在系统联调时，由于微信客户端强缓存造成可视化结果图无法更新的问题，在后端给静态文件路由对应的响应头中加入 Cache-Control: no-store,no-cache，从而解决缓存穿透带来的交互问题。

为了保证服务器硬盘空间的有效利用而设计了一个独立于主线程的异步资源回收线程，在此线程中监控文件最后修改时间（mtime），对超过 24 小时未生成的临时检测结果图像以及局部切图进行删除操作，防止长时间占用磁盘空间影响系统的正常运行。

4.4 系统功能与性能测试

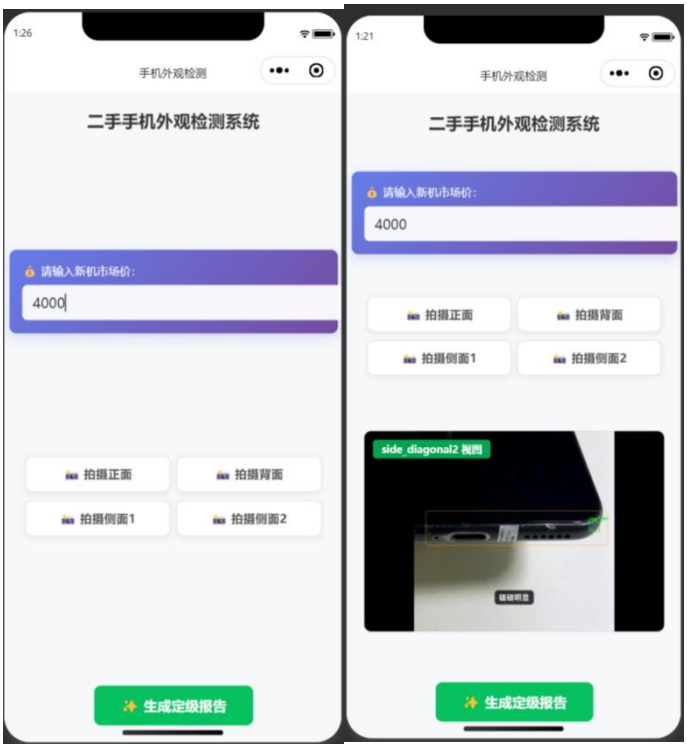
4.4.1 软硬件联调与真机测试环境

系统在局域网内完成联调，在后端服务监听 0.0.0.0:8000 端口情况下，微信小程序

在开发者工具以及真机设备上利用统一封装常量 API_BASE 实现跨域请求操作。测试设备包括各种品牌的主流手机和平板电脑，主要是为了测试前端调用系统的摄像头相关功能以及图片压缩等是否正常。

4.4.2 业务流程全闭环功能演示

系统实现完整的图像获取到估价过程。如图 4.6 所示，在用户输入新机基准价之后，依次拍摄手机四个角度的照片。每张照片上传之后，在界面上方可以看到带有高亮边界框瑕疵标注照片。四个角度拍摄完成并且点击生成报告之后，系统会立即显示定级报告页面。



(a) (b)



(c) (d)

图 4.6 微信小程序端全业务流程操作界面

在报告面板中，不仅清晰展示各个维度扣分之后得到总评分（例如：71.26 分）以及所对应商业等级（C 级/八成新），而且根据动态调价引擎换算出预测回收价格，在报告下方还附有“视觉证据链”截图以及算法透明度公式面板，有利于提高评估结果商业公信力，如图 4.7。



图 4.7 智能定级报告及底层算法透明度展示

4.4.3 推理延迟与并发响应性能评估

最后，对部署系统的相关重要性能参数进行多次压力测试，在 GPU 加速环境下以及纯 CPU 环境下都进行了相应测试并将其结果列于表 4-4 中。

表 4-4 系统核心模块性能压测结果

测试指标	CUDA 加速模式	CPU 模式	达标要求
单视角推理延迟	≤ 150 ms	≤ 450 ms	< 500 ms（实时）
四视角全流程耗时	< 1.5 s	< 3.0 s	< 5.0 s
定级报告生成耗时	< 200 ms	< 200 ms	< 500 ms
并发处理能力	支持多用户并发	顺序处理	≥ 基本可用
模型文件大小	38.4 MB (ONNX)	—	< 100 MB
系统内存占用	~1.2 GB	~0.6 GB	< 4 GB

实验结果显示，在 CUDA 加速的情况下，单视角端到端推理延迟在 150ms 以内，在整个过程中采集四个视角并进行评级所需的时间不超过 1.5 秒左右，已经可以达到移动设备上的人机交互“感觉不到延迟”。而在仅使用 CPU 情况下，单次推理延迟（约 450ms）以及整个过程所需时间（<3.0 秒）也能保证基本的商业实用性。系统的大规模并发、非阻塞性能以及较小的开销（内存约 1.2GB）也说明本方案对小商户具有较高的推广价值。

4.5 本章小结

本章通过大量的客观实验数据以及工程实测结果来说明第 3 章提出的方法具有有效性及可行性，在算法上，10 个消融实验表明：对于有具体物理限制的实际工业检测任务，盲目增加网络结构复杂度（例如添加 Inner-IoU 以及 CBAM）会带来负增益，而合理利用物理先验的信息进行数据增强（翻转和动态 Mosaic）能够获得 5.8%的提升；而在系统实现上，基于 ONNX 和 FastAPI 搭建高效率平台配合微信小程序实现轻量级交互设计，最终实现了响应迅速、端到端完整二手手机外观智能评级工具，达成了本课题的应用落地目标。

第 5 章 全文总结与展望

5.1 主要研究工作总结

本文以“基于改进 YOLOv11 的二手手机外观瑕疵检测与智能定级系统设计”为主题，在“数据重构-算法寻优-系统落地”的思路下开展相关研究工作并取得一定成果，主要工作及成果如下：

（1）搭建高纯净手机表面瑕疵专用数据集。由于一般的工业数据集中存在的多种材料（高反光玻璃、金属拉丝）混杂的情况，再加上网络上自动抓取的数据效率极低，在此从零开始制作一个包含 2707 张真实图片的数据集。舍弃大量有高频噪声的 AI 辅助标注，采用严格的边界框标注并结合物理增强的方法使 YOLOv11s 的基础模型 mAP@0.5 从最初的约 50%提高到 90.7%，说明数据对于工业缺陷检测的重要性。

（2）基于消融实验得到最优的数据驱动检测方法。本工作并非简单地堆砌多种先进技术手段而是在十个不同条件下的消融实验中，从理论上并用具体数据证明一般性增强部件的不足之处。实验客观上否定了 Inner-IoU 对于极端长宽比缺陷的有效性以及 CBAM 对于高反光小目标造成的影响（mAP 最大下降 4.3%）。从而确定一种结合空间对称性建模（flipud=0.5）和动态背景复杂度均衡（mosaic=0.4）的数据增强方式，在无参数的情况下使 mAP@0.5 达到 0.965，召回率为 92.16%。

（3）开发了一套从头到尾的智能化定级全流程系统。弥补了计算机视觉特征到商业定价之间缺失的一环。“对角两拍法”，即一种简易多角度拍摄方式，在此基础上还提出了利用对数平滑方法进行非线性加权扣分的方法，将瑕疵种类、占比以及视角作为三个维度进行综合评定得到客观的 S/A/B/C/D 成色等级，在工程实现上使用 ONNX 模型转换以及 FastAPI 异步方式配合微信小程序原生前端，达到每次预测耗时小于 150 毫秒并且能够支持大量请求而不影响性能的效果。

5.2 系统局限性与盲区分析

虽然该系统对于二维外观缺陷检测以及分级具有良好的效果，但是从严格的工程应用角度考虑，目前该系统还存在一些不足之处及评价指标的缺失。

（1）无法进行三维几何深度感知。现有检测方法都是基于二维 RGB 图像进行像素

级特征提取，而对瑕疵所处的深度（Z 轴方向）无感知能力。比如，轻微掉漆边框与造成内部损坏严重凹坑（磕碰），在一定角度下从二维平面看两者具有较高相似性。单纯通过面积占比扣分，在有深度变形情况下存在较大偏差。

（2）整机内部及功能性损耗的评估盲区。本系统仅针对“外观成色”进行判定，“外观成色”并不能完全反映一台二手手机的真实市场价值，在实际交易过程中，屏幕老化（烧屏）、电池寿命下降、内部主板损坏以及非原装部件等因素都会对二手手机的价值产生重大影响，而这些都超出了当前系统的判断范围，只能给出一个“外观评分”，而不是一个准确的“整机评价”。

（3）极端光照条件下的鲁棒性问题。虽然动态 Mosaic 可以提高模型对于复杂背景的鲁棒性，在真实应用当中，如果在较强逆光或者非常黑暗的情况下拍摄，由于手机屏幕的高光溢出会造成一些细微划痕无法被检测到，系统对于所处光照环境还是有一定的要求。

（4）定级权重参数依赖经验。目前扣分模型中瑕疵严重度基准值（例如裂纹权重设置为 50）以及视角位置权重（例如正面设置为 1.0）均是根据业内调查及经验拟定，在大量实际市场交易成交数据基础上未经过严格统计学上的回归与校准。

5.3 未来研究与迭代展望

为了解决以上不足之处，在今后的研究及系统更新中将着重考虑以下几个方面。

（1）端侧轻量化闭环以及隐私计算。目前系统需依托云上服务器完成推理计算，在图片上传时会有一定延时并且有安全隐患。后续将针对最优 YOLOv11 模型进行 INT8 量化及结构化剪枝，尝试使用 WebAssembly 或者微信小程序原生 AI 推理框架（如 WNN）进行端侧部署，以达到脱离网络即刻即可进行毫秒级本地检测的目的。

（2）多模态融合的整机定级体系设计。突破单一视觉检测限制，在未来可以利用微信小程序 API 或者开发专用诊断 SDK 获取设备硬件健康情况（例如电池充放电次数、屏幕多点触控检测、陀螺仪状态等）。将“机器视觉外观评分”与“软硬件健康评分”进行多模态加权融合形成更高商业价值的整体评价标准。

（3）基于真实交易数据驱动的参数自校准。采用机器学习中回归方法，将定级系统扣分权重参数化，在大量二手交易平台“瑕疵图象-最终成交价格”样本基础上建立监督学

习模型，对公式中 W_{type} 与 L_{pos} 进行实时调整，让定级算法可以自主学习并适应各细分市场对于价格的不同关注程度。

参考文献

[1] Khanam R, Hussain M. YOLOv11: An Overview of the Key Architectural Enhancements[EB]. arXiv, 2024.

[2] Sapkota R, Karkee M. Ultralytics YOLO Evolution: An Overview of YOLO26, YOLO11, YOLOv8 and YOLOv5 Object Detectors for Computer Vision and Pattern Recognition[EB/OL]. (2025-10-06)[2026-05-23]. https://arxiv.org/abs/2510.09653v3.

[3] Mohandas R, Southern M, Fitzpatrick C, et al. Deep learning enabled computer vision in remanufacturing and refurbishment applications: defect detection and grading for smart phones[J]. Journal of Remanufacturing, 2025, 15(1): 65-95.

[4] 陶显, 侯伟, 徐德. 基于深度学习的表面缺陷检测方法综述[J]. 自动化学报, 2021, 47(5): 1017-1034.

[5] Mao M, Hong M. YOLO Object Detection for Real-Time Fabric Defect Inspection in the Textile Industry: A Review of YOLOv1 to YOLOv11[J]. Sensors, 2025, 25(7): 2270.

[6] Cheng Y, Cao Y, Yao H, et al. A comprehensive survey for real-world industrial surface defect detection: Challenges, approaches, and prospects[J]. Journal of Manufacturing Systems, 2026, 84: 152-172.

[7] Shukla V, Shukla A, SK S P, et al. A systematic survey: role of deep learning-based image anomaly detection in industrial inspection contexts[J]. Frontiers in Robotics and AI, 2025, 12: 1554196.

[8] Qiao Q, Hu H, Ahmad A, et al. A review of metal surface defect detection technologies in industrial applications[J/OL]. IEEE Access, 2025. https://ieeexplore.ieee.org/abstract/document/10897983/.

[9] Jiang D, Wang R. Research on the generation method of missing data for soft measurement based on GAN[J]. Xibei Gongye Daxue Xuebao/Journal of Northwestern Polytechnical University, 2024, 42(2): 344-352.

[10] 成科扬, 丁杨柳, 詹永照, 等. 基于回顾蒸馏学习的无监督工业品缺陷检测方法[J]. 南京大学学报(自然科学版), 2022, 58(6): 1030-1040.

[11] 王晓婷, 刘婷婷. 基于改进 YOLOv11 的焊缝缺陷高精度检测方法[J]. 计算机应用研究, 2025, 42(10): 3192-3200.

[12] 戚 翔 宇 . Improvement of the YOLOv11 Defect Detection Algorithm[J]. Computer Science and Application, 2025, 15(01): 108-116.

[13] 吴旭, 狄海廷, 吴小康. 基于改进 YOLOv11n 的射频组件外观缺陷检测分析[J]. 无损检测, 2026, 48(3): 44-49.

[14] Wang C, Han Y, Yang C, et al. CF-YOLO for small target detection in drone imagery based on YOLOv11 algorithm[J]. Scientific Reports, 2025, 15(1): 16741.

[15] Wang Z, Ding T, Liang S, et al. Workpiece surface defect detection based on YOLOv11 and edge computing[J]. PLOS One, 2025, 20(7): e0327546.

[16] H. Han, R. Yang, S. Li, R. Hu and X. Li. SSGD: A Smartphone Screen Glass Dataset for Defect Detection. ICASSP 2023 - 2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), Rhodes Island, Greece, 2023: 1-5

[17] Li J, Long H, Liu M, et al. Smartphone screen surface defect detection using dynamic large separable kernel attention and multi-scale feature bi-directional path aggregation network[J]. Scientific Reports, 2025, 15(1): 40620.

[18] Wu P, Zhou H, Yu Y, et al. SSGDD-YOLO: Multiscale Feature Fusion and Multiattention-Based YOLO

for Smartphone Screen Glass Defect Detection[J]. IEEE Sensors Journal, 2025, 25(4): 6982-6994.
[19] 伍济钢, 成远, 邵俊, 等. 面向智能手机玻璃盖板缺陷检测的 YOLOv3 改进和应用[J]. 液晶与显示, 2021, 36(12): 1728-1736.
[20] 周思瑜, 徐慧英, 朱信忠, 等. 基于改进 YOLOv8n 的手机屏幕瑕疵检测算法：PGS-YOLO[J]. 计算机工程, 2025, 51(5): 326-339.
[21] 陈湘尹. 基于 YOLOv8 的手机盖板玻璃表面瑕疵检测方法研究[D]. 东莞理工学院, 2025.
[22] Ye T, Huang S, Qin W, et al. YOLO-FIX: Improved YOLOv11 with Attention and Multi-Scale Feature Fusion for Detecting Glue Line Defects on Mobile Phone Frames[J]. Electronics, 2025, 14(5): 927.
[23] Wu J, Chen H, Yu X, et al. MSAdaNet: An Adaptive Multi-Scale Network for Surface Defect Detection of Smartphone Components[J]. Sensors, 2026, 26(7): 2091.
[24] Zhuo S, Zhou X, Cai J, et al. A lightweight network for phone surface defect detection with industrial deployment on RK3568 edge devices[J]. PLOS One, 2025, 20(12): e0336971.
[25] Liu Y, Liu F, Huang Y, et al. The Real-Time Pavement Distress Detection System Based on Edge-Cloud Collaborative Computing[J]. IEEE Transactions on Intelligent Transportation Systems, 2025, 26(7): 10512-10522.
[26] Goodfellow I J, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets[J]. Advances in neural information processing systems, 2014, 27.
[27] Woo, S., Park, J., Lee, J. Y., & Kweon, I. S. Cbam: Convolutional block attention module. In Proceedings of the European conference on computer vision (ECCV),2018: 3-19.
[28] Zhang, H., Wang, Y., Dayoub, F., & Sunderhauf, N. Varifocalnet: An iou-aware dense object detector. In Proceedings of the IEEE/CVF conference on computer vision and pattern recognition,2021: 8514-8523.
[29] Bochkovskiy A, Wang C Y, Liao H Y M. YOLOv4: Optimal Speed and Accuracy of Object Detection[EB]. arXiv preprint arXiv:2004.10934 (2020).
[30] Lai S, Ge S, Guo X, et al. CD-Mosaic: A Context-Aware and Domain-Consistent Data Augmentation Method for PCB Micro-Defect Detection[J]. Electronics, 2026, 15(4): 767.
[31] Paszke A, Gross S, Massa F, et al. Pytorch: An imperative style, high-performance deep learning library[J]. Advances in neural information processing systems, 2019, 32.
[32] Durall R, Keuper M, Keuper J. Watch your up-convolution: Cnn based generative deep neural networks are failing to reproduce spectral distributions[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 7890-7899.
[33] Terven J, Córdova-Esparza D M, Romero-González J A. A Comprehensive Review of YOLO Architectures in Computer Vision: From YOLOv1 to YOLOv8 and YOLO-NAS[J]. Machine Learning and Knowledge Extraction, 2023, 5(4): 1680-1716.
[34] Chen Y, Li Y, Kong T, et al. Scale-aware automatic augmentation for object detection[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2021: 9563-9572.

致谢

岁月不居，时节如流。一晃四年，在湖北工业大学底特律绿色工业学院本科生活就要结束。从最初迷茫摸索到如今系统落地，万千感慨萦绕心间。在此，我要感谢在我人生旅途中照亮我前行道路的所有老师、同学以及家人。

桃李不言，下自成蹊。本论文完成离不开我的导师——熊才权教授的支持，在我开题之初指明方向，在我构建数据集中推翻重来时给我信心；在设计消融实验时反复斟酌，在我写论文一字一句斟酌过程中，熊老师以渊博的知识、一丝不苟的学习态度以及仁慈的师者之心一直关心指导着我。每一份初稿后面那一行又一行细致批注不只是对我代码和文章修改，也是无形中让我明白什么是“工程务实”，什么是“学术求真”。高山仰止，景行行止。能够在我本科生涯最后一刻得到熊老师的教诲，是我一生之幸。

饮水思源，缘木思本。本人要向湖北工业大学以及底特律绿色工业学院四年对我精心培养表示衷心感谢。这里的一幢幢明亮的教学楼、一盏盏通宵达旦的实验室灯光、一个个诲人不倦的老师们，都是我从一个无知少年一步步蜕变成一个合格软件工程师所踏过的阶梯。学校不仅教会了我专业技能，还教给我独立思考、勇于面对困难的精神，这是我在以后的人生道路上一笔巨大的财富。另外，还要感谢软件二班同学们，是你们陪我一起熬过一个又一个编写程序的夜晚，在那里讨论问题、互相帮助，使那段乏味的学习生活变得丰富多彩。

谁言寸草心，报得三春晖。在这里我想对我最爱我的父母说一声谢谢。二十多年养育之恩，无法回报。在漫长求学生涯中，无论是得意时喜悦分享，还是遭遇困难时忧虑烦恼，一直有你们坚定地支撑着我。是你们理解、体谅、支持，为我挡住外面风风雨雨，让我可以安心地坐在电脑屏幕前，专心致志开辟自己一片天地。这篇论文每一段文字背后都是你们汗水和期望。

最后，我想对参与本次毕业设计评审以及答辩的所有老师们表示衷心感谢。感谢您们在百忙之中抽出时间来阅读这篇论文，在答辩中您们高屋建瓴的观点，严厉但又不失公平公正的评价都是我在踏入社会之前收到的一份最宝贵的礼物，更是我今后不断进步的动力源泉。

学海无涯，纸短情长。论文既是结束也是开始。因个人能力有限，在文章中一定有不足之处，在此我虚心接受各位老师的指正。行而不辍，未来可期！